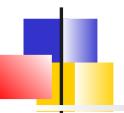


Elastic Search Le moteur de recherche

David THIBAU - 2024

david.thibau@gmail.com



Agenda

Introduction

- L'offre
- Concepts de base
- Les API ELS

Indexation et documents

- Document API
- Librairie clientes
- Pipelines d'ingestion
- API Search Lite

Mapping et analyseurs

- Types et champs full-text
- Contrôler le mapping
- Mapping dynamique
- Analyseur custom
- API de Réindexation

Recherche avec DSL

- Syntaxe DSL
- Principaux opérateurs
- Tri et pertinence
- Contrôle du score

Recherche avancée

- Recherche avec préfixe
- Recherche phrase
- Recherche floue
- Surbrillance
- Agrégations
- Géo-localisation

Monitoring

- Index et usage
- Annexes



L'offre Concepts de base Les APIs



La société *elastic* propose une suite de produit nommé ElastickStack qui s'adresse à 2 aspects du BigData :

- La Recherche en temps réel
 Des données indexées en permanence sont disponibles à la recherche, la latence due à l'indexation est négligeable (Near Real Time)
- Analyse de données en temps réel.
 Les données sont agrégées en temps-réel afin de fournir des visualisations et tableau de bords permettant de détecter des informations pertinentes.

La clé de voûte de cette suite est le produit ElasticSearch



ElasticSearch

ElasticSearch est un serveur offrant une API REST permettant :

- De stocker et indexer tous types de données (Documents bureautique, tweet, fichiers journaux, métriques, ...)
- D'effectuer des requêtes de recherche (structurées, full-text, langage naturel, géographiques)
- D'effectuer différents types d'agrégations multi-critères



Caractéristiques de l'offre

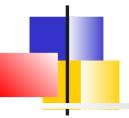
- Architecture massivement distribuée et scalable en volume et en charge => Big Data, performance remarquable
- Haute-disponibilité via la réplication
- Muti-tenancy ou multi-index. La base documentaire contient plusieurs index dont les cycles de vie sont complètement indépendants
- Basée sur la librairie de référence **Lucene** => Recherche fulltexte, prise en compte des langues, du langage naturel, ...
- Stockage structuré des documents mais sans schéma préalable, possibilité d'ajouter des champs à un schéma existant
- API RESTFul très complète
- OpenSource





Apache Lucene

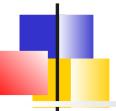
- Projet Apache Démarré en 2000, utilisé dans de nombreux produits
- La « couche basse » d'ELS : une librairie Java pour écrire et rechercher dans les fichiers d'index.
- ELS ajoute à lucène :
 - Le clustering : distribution et la scalabilité,
 - Une API REST
 - La simplification de la configuration
 - Des fonctionnalités d'analyse de données (agrégation, machine learning)



ELS vs SolR

La fondation Apache propose **SolR** qui est très proche d'ELS en termes de fonctionnalités

	SOLR	ELS
Installation & Configuration	Documentation très détaillée	Simple et intuitif
Indexation/ Recherche	Orienté Texte	Texte et autres types de données pour les agrégations
Scalability	Cluster via ZooKeeper et SolRCloud	Nativement en cluster
Communauté	Importante mais stagnante	A explosé ces dernières années
Documentation	Très complète et très technique	Très complète, facile d'accès, bcp de tutoriaux



Distributions

La distribution permettant d'installer *ElasticSearch* est disponible sous plusieurs formes :

- Archive ZIP, TAR
- Package : yum, apt, ...
- Containers

Versions

- 8.0.0 : Février 2022

- 7.0.0 : 10 Avril 2019

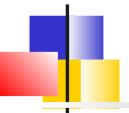
- 6.0.0 : Novembre 2017

- 5.0.0 : Octobre 2016

- 2.4.1 : Septembre 2016

- 2.4.0 : Août 2016

Configuration



Il existe plusieurs fichiers principaux de configuration :

- elasticsearch.yml : Propriétés propres au nœud ELS
- *jvm.options* : Options de la JVM
- log4j2.properties : Verbosité et support de traces
- Annuaire utilisateur et certificats SSL

La configuration par défaut permet de démarrer rapidement après une indexation. En production, il faut quand même modifier certains paramètres.

Depuis la version 8.x, la sécurité est activée par défaut



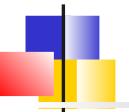
Bootstrap check

Au démarrage ELS effectue des vérifications sur l'environnement . Si ces vérifications échouent :

- En mode développement, des warning sont affichés dans les logs
- En mode production (écoute sur une adresse publique), ELS ne démarre pas

Ces vérifications concernent entre autre :

- Dimensionnement de la heap pour éviter les redimensionnements et le swap
- Limite sur les nombre de descripteurs de fichiers très élevée (65,536)
- Autoriser 2048 threads
- Taille et zones de la mémoire virtuelle (pour le code natif Lucene)
- Filtre sur les appels système
- Vérification sur le comportement lors d'erreur JVM ou de OutOfMemory



L'offre Concepts de base Les APIs



Cluster

Un **cluster** est un ensemble de serveurs (nœuds) qui contient l'intégralité des données et offre des capacités de recherche sur les différents nœuds

- Il est identifié par son nom unique sur le réseau local (par défaut : "elasticsearch").
- => Un cluster peut être mono-noeud
- => Un nœud ne peut pas appartenir à 2 clusters distincts



Nœud

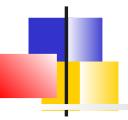
Un **nœud** est un processus *els* identifié par un nom unique qui a rejoint un cluster

Le nombre de nœuds dans un cluster n'est pas limité, les nœud peuvent être ajoutés supprimés sans (trop) perturber le cluster

Un nœud peut avoir un ou plusieurs rôles :

- *master* : Peut être élu pour coordonner le cluster
- data : Stocke les données
- *ingest* : Ingère les données
- ml : Exécutes des jobs de Machine Learning

— ...



Index

Un **index** est une collection de documents qui ont des caractéristiques similaires

 Par exemple un index pour les données client, un autre pour le catalogue produits et encore un autre pour les commandes

Un index est identifié par un nom (en minuscule)

 Le nom est utilisé pour les opérations de mise à jour ou de recherche

Dans un cluster, on peut définir autant d'index que l'on veut



Shard

Un index peut stocker une très grande quantité de documents qui peuvent excéder les limites d'un simple nœud.

Pour pallier ce problème, ELS permet de sousdiviser un index en plusieurs parties nommées **shards**

 Le nombre de shards est défini à la création de l'index

Chaque *shard* est un index indépendant contenant un sous-ensemble des données hébergé sur un nœud *data* du cluster



Apports du sharding

Le sharding permet :

- De scaler le volume de contenu
- De **distribuer** et paralléliser les opérations => augmenter les performances

La mécanique interne de distribution lors de l'indexation et d'agrégation de résultat lors d'une recherche est complètement gérée par ELS et donc transparente pour l'utilisateur



Réplica

Pour pallier à toute défaillance, un shard peut être **répliqué**

Le nombre de réplique est défini à la création mais peut être modifié dynamiquement

La réplication permet

- La haute-disponibilité dans le cas d'une défaillance d'un nœud (Une réplique ne réside jamais sur le nœud hébergeant le shard primaire)
- De scaler le volume des requêtes car les recherches peuvent être exécutées sur toutes les répliques en parallèle.



Document

Un **document** est l'unité basique d'information stocké par les shards.

Il est constitué d'un ensemble de champs typés

Il peut être représenté avec JSON



L'offre
Concepts de base
Les APIs



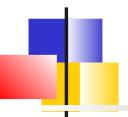
API d'ELS

ELS expose donc une API REST utilisant JSON

L'API est divisée en catégorie

- API document (CRUD sur document)
- API d'index (CRUD sur Index)
- API de recherche (_search)
- API cluster : monitoring du cluster (_cluster)
- API cat : Format de réponse tabulée pour gestion du cluster (_cat)
- API ingest : Ingestion et transformation des données sources
- API ML: Gestion des jobs de ML

— ...



Les différentes API respectent un ensemble de conventions communes

- Possibilité de travailler sur plusieurs index
- Fonctions de calcul de Date pour spécifier les noms d'index.
- Options/paramètres communs



Multiple index

La plupart des APIs qui référencent un index peuvent s'effectuer sur plusieurs index :

```
test1,test2,test3
*test
+test*,-test3
_all
```



Noms d'index avec Date Math

La résolution d'index avec Date Math permet de restreindre les index utilisés en fonction d'une date.

Il faut que les index soient nommés avec des dates

La syntaxe est :

```
<static_name{date_math_expr{date_format|time_zone}}>
```

```
- date_math_expr : Expression qui calcul une date
```

- date_format : Format de rendu
- time_zone : Fuseau horaire

Exemples:

```
GET /<logstash-{now/d}>/_search => logstash-2017.03.05
GET /<logstash-{now/d-1d}>/_search => logstash-2017.03.04
GET /<logstash-{now/M-1M}>/_search => logstash-2017.02
```



Options communes (1)

Les paramètres utilisent l'underscore casing

?pretty=true: JSON bien formatté

?format=yaml : Format yaml

?human=false : Si la réponse est traitée par un outil

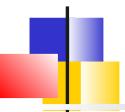
?filter_path : Filtre de réponse, permettant de spécifier les données de la réponse

Ex : GET /_cluster/state?pretty&filter_path=nodes

?flat_settings=true : Les settings sont renvoyés en utilisant la notation « . » plutôt que la notation imbriquée

?error_trace=true : Inclut la stack trace dans la réponse

Alternatives Clients



- Clients REST classiques : curl, navigateurs avec add-ons, SOAPUI, ...
- Librairies fournies par Elastic : Java, Javascript, Python, Groovy, Php, .NET, Perl Ces librairies permettent l'équilibrage de charge sur les nœuds du cluster
- Enfin, le client le plus confortable est la Dev Console de Kibana

DevConsole Kibana



La *DevConsole* est composée de 2 onglets :

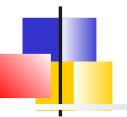
- L'éditeur permettant de composer les requêtes
- L'onglet de réponse

La console comprend une syntaxe proche de Curl





- La console permet une traduction des commandes CURL dans sa syntaxe
- Elle permet l'auto-complétion, l'auto indentation
- Passage sur une seule ligne de requête (utile pour les requêtes BULK)
- Permet d'exécuter plusieurs requêtes
- Peut changer de serveur ElasticSearch
- Raccourcis clavier
- Historique des recherche



Indexation et Documents

Document API

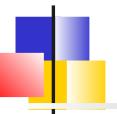
Librairies clientes
Pipelines d'ingestion
API Search Lite



ElasticSearch est une base documentaire distribuée.

Il est capable de stocker et retrouver des structures de données (sérialisées en documents JSON) en temps réel

- Les documents sont constitués de champs.
- Chaque champ a un type
- Certains champs de type texte sont analysés pour permettre des recherche full-text



Exemple document

```
"name": "John Smith",
                      // String
"age": 42,
                        // Nombre
"confirmed": true, // Booléen
"join_date": "2014-06-01", // Date
"home": {
                         // Imbrication
  "lat": 51.5,
  "lon": 0.1
},
                   // tableau de données
"accounts": [
  "type": "facebook",
  "id": "johnsmith"
  }, {
  "type": "twitter",
  "id": "johnsmith"
```

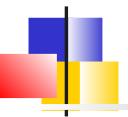


Méta-données

Des méta-données sont également associées à chaque document.

Les principales méta-données sont :

- _index : L'emplacement où est stocké le document
- _id : L'identifiant unique
- version : N° de version du document



L'API document est l'API permettant les opérations CRUD sur les documents

- Création : POST
- Récupération à partir de l'ID : GET
- Mise à jour : PUT
- Suppression : *DELETE*



Indexation et *id* de document

Un document est identifié par ses méta-données *_index* et *_id*.

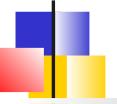
Lors de l'indexation (insertion dans la base), il est possible

- de fournir l'ID
- ou de laisser ELS le générer



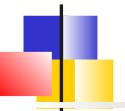
Exemple avec Id

```
POST /{index}/_doc/{id}
  "field": "value",
}
  "_index": {index},
  "_id": {id},
  "_version": 1,
  "created": true
```



Exemple sans Id

```
POST /{index}/_doc/
  "field": "value",
  "_index": {index},
  "_type": {type},
  "_id": "wM00SFhDQXGZAWDf0-drSA",
  "_version": 1,
  "created": true
```



Récupération d'un document

La récupérant d'un document peut s'effectuer en fournissant l'identifiant complet :

```
GET /{index}/_doc/{id}?pretty
```

La réponse contient le document et ses métadonnées. Exemple :

```
{ "_index" : "website",
    "_type" : "blog",
    "_id" : "123",
    "_version" : 1,
    "found" : true,
    "_source" : {
        "title": "My first blog entry",
        "text": "Just trying this out...",
        "date":"2014/01/01" } }
```



Partie d'un document

Il est possible de ne récupérer qu'une partie des données.

Exemples:

```
# Les méta-données + les champs title et text
GET /website/_doc/123?_source=title,text
# Juste la partie source sans les méta-données
GET /website/_doc/123/_source
# Vérifier qu'un document existe (Retour 200)
HEAD /website/_doc/123
```



Mise à jour

Les documents stockés par ELS sont immuables.

=> La mise à jour d'un document consiste à indexer une nouvelle version et à supprimer l'ancienne.

La suppression est asynchrone et s'effectue en mode batch (suppression de toutes les répliques)



Mise à jour d'un document

```
PUT /website/_doc/123
"title": "My first blog entry",
"text": "I am starting to get the hang of this...",
"date": "2014/01/02"
"_index" : "website",
"_type" : "blog",
"_id" : "123",
"_version" : 2,
"created": false
}
```



Création ... if not exist

2 syntaxes sont possible pour créer un document seulement si celui-ci n'existe pas déjà dans la base :

PUT /website/_doc/123?op_type=create

Ou

PUT /website/_doc/123/_create

Si le document existe, ELS répond avec un code retour 409

Suppression d'un document

```
DELETE /website/ doc/123
  "found" : true,
  " index" : "website",
  " type" : "blog",
  " id" : "123",
  " version" : 3
```



Concurrence des mises à jour

Elasticsearch gère la concurrence des accès à sa base par une approche **optimiste**

En s'appuyant sur le champ _version, il s'assure qu'une requête de mise à jour s'applique sur la dernière version du document.

Si ce n'est pas le cas (i.e., le document a été mis à jour par une autre thread entre-temps), il répond avec un code d'erreur 409

```
{
"error" : "VersionConflictEngineException[[website][2] [blog][1]:
version conflict, current [2], provided [1]]",
"status" : 409
}
```

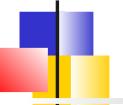


Mise à jour partielle

Les documents sont immuables : ils ne peuvent pas être changés, seulement remplacés

> La mise à jour de champs consiste donc à ré-indexer le document et supprimer l'ancien

L'API <u>update</u> utilise le paramètre doc ou script pour fusionner les champs fournis avec les champs existants



Exemple

```
POST /website/_update/1
{
  "doc" : {
    "tags" : [ "testing" ],
    "views": 0
"_index" : "website",
"_id" : "1",
"_type" : "blog",
"_version" : 3
```



Utilisation de script

Un script (*Groovy* ou *Painless*) peut être utilisé pour changer le contenu du champ _source en utilisant une variable de contexte : ctx. source

Exemples:

```
POST /website/_doc/1/_update {
    "script" : "ctx._source.views+=1"
}
POST /website/_doc/1/_update {
    "script" : {
        "source" : "ctx._source.tags.add(params.new_tag)",
        "params" : {
            "new_tag" : "search"
} }
```

<u>N.B.</u> Les scripts peuvent également être chargés à partir de l'index particulier *.scripts* ou de fichier de configuration. Ils peuvent être utilisés dans d'autres contextes qu'une mise à jour.



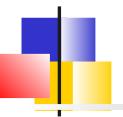
Bulk API

L'API **bulk** permet d'effectuer plusieurs ordres de mise à jour (création, indexation, mise à jour, suppression) en 1 seule requête

- => C'est le mode batch d'ELS.

Attention: Chaque requête est traitée séparément. L'échec d'une requête n'a pas d'incidence sur les autres.

=> Pas de notion de transactions.



Format de la requête

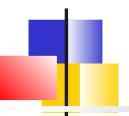
Le format de la requête est :

```
{ action: { metadata }}\n
{ request body }\n
{ action: { metadata }}\n
{ request body } \n
```

Le format consiste à des documents JSON sur une ligne concaténés avec le caractère \n.

- Chaque ligne (même la dernière) doit se terminer par
 \n
- Les lignes ne peuvent pas contenir d'autre \n

 Le document JSON ne peut pas être joliment formatté

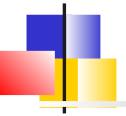


Syntaxe

La ligne action peut spécifier :

- create : Création d'un document non existant
- index : Création ou remplacement d'un document
- update : Mise à jour partielle d'un document
- delete: Suppression d'un document.

Elle précise les méta-données : _id, _index



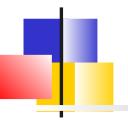
Exemple

```
POST /website/_bulk // website est l'index par défaut
{ "delete": { "_id": "123" }}
{ "create": { "_index": "website2", "_id": "123" }}
{ "title": "My first blog post" }
{ "index": { }
{ "title": "My second blog post" }
{ "update": { "_id": "123"} }
{ "doc" : {"title" : "My updated blog post"} }
```



Réponse

```
"took": 4,
"errors": false,
"items": [
{ "delete": { " index": "website",
  " type": " doc", " id": "123",
  " version":2,
  "status": 200,
  "found": true
 }},
{ "create": { "_index": "website",
  "_type": "_doc" , "_id": "123",
  " version": 3,
  "status": 201
}},
{ "create": { " index": "website",
  " type": " doc", " id": "EiwfApScQiiy7TIKFxRCTw",
  " version": 1,
  "status": 201
}},
{ "update": { " index": "website",
  "_type": "_doc", "_id": "123",
  " version": 4,
  "status": 200
}} ] }}
```



Indexation et Documents

Document API
Librairies clientes
Pipelines d'ingestion
API Search Lite



Clients Elastic Search

Elastic fournit et supporte des clients écrits en différents langages :

- Java
- JavaScript
- -.NET
- PHP
- Perl
- Python
- Ruby
- Go
- Eland
- Rust



Principes

Pour chaque technologie, le principe consiste à construire un client à partir de la topologie du cluster ELS.

Le client permet de répartir la charge des requêtes Ensuite, les appels de l'API sont effectués en utilisant

- Des méthodes dédiées au langage (Java, .NET)
- Directement le corps JSON de la requête (Javascript)

Des méthodes spécifiques sont proposées pour gérer la tolérance aux pannes



Exemple Java



Exemple Javascript

```
var elasticsearch = require('elasticsearch');
var client = new elasticsearch.Client({
   host: 'localhost:9200',
   log: 'trace'
});
client.search({
   q: 'pants'
}).then(function (body) {
   var hits = body.hits.hits;
}, function (error) {
   console.trace(error.message);
});
```



Indexation et Documents

Document API
Librairies clientes
Pipelines d'ingestion
API Search Lite



Concepts de l'ingestion

Certains nœuds du cluster peuvent être spécialisés en nœud de type *ingest-nodes*. Leurs CPU sont alors utilisés pour pré-traiter des documents avant leur indexation

Les pré-traitements sont identifiés par une pipeline

Le nom de la pipeline est précisée via le paramètre *pipeline* sur une requête bulk ou d'indexation

```
PUT my-index/_doc/my-id?pipeline=my_pipeline_id
{ "foo": "bar"}
```



Pipeline

Une **pipeline** est définie par 2 champs :

- Une description
- Une liste de processeurs

Les processeurs correspondent au rétraitement effectués et s'exécutent dans leur ordre de déclaration



Processeurs

ELS fournit de nombreux processeurs.

- Enrichissement append, date_index_name, attachment, geo_ip, ...
- Transformationconvert, grok, rename, gsub, split, ...
- Filtredrop, remove, ...
- Gestionnaire d'erreurs ou de routing fail, pipeline, reroute, ...
- Scriptingfor_each, script, ...



Processeur attachment

Le processeur **attachment** permet d'extraire le texte des fichiers dans les formats bureautiques les plus communs

Il utilise *Tika*



Ingest API

L'API _*ingest* permet de gérer les pipelines :

- PUT pour ajouter ou mettre à jour une pipeline
- **GET** pour retourner une pipeline
- DELETE pour supprimer
- SIMULATE pour simuler un appel à une pipeline



Usage

```
#Création de la pipeline nommée attachment
PUT ingest/pipeline/attachment
  "description" : "Extract attachment information",
  "processors" : [
    { "attachment" : { "field" : "data" } }
#Utilisation de la pipeline lors de l'indexation d'un doc.
PUT my_index/_doc/my_id?pipeline=attachment
  "data":
"e1xydGYxXGFuc2kNCkxvcmVtIGlwc3VtIGRvbG9yIHNpdCBhbWV0DQpccGF
yIH0="
```



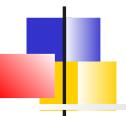
Résultat

```
GET my_index/my_type/my_id
  "found": true,
  "_index": "my_index",
  "_type": "my_type",
  "_id": "my_id",
  " version": 1,
  " source": {
    "data":
"e1xydGYxXGFuc2kNCkxvcmVtIGlwc3VtIGRvbG9yIHNpdCBhbWV0DQpccGFyIH0=",
    "attachment": {
      "content_type": "application/rtf",
      "language": "ro",
      "content": "Lorem ipsum dolor sit amet",
      "content length": 28
```



Indexation et Documents

Document API
Librairies clientes
Pipelines d'ingestion
API Search Lite



APIs de recherche

Il y a donc 2 API de recherche:

- Une version simple qui attend que tous ses paramètres soient passés dans la chaîne de requête
- La version complète composée d'un corps de requête JSON qui utilise un langage riche de requête appelé DSL

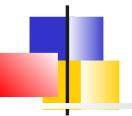


Search Lite

La version *lite* est cependant très puissante, elle permet à n'importe quel utilisateur d'exécuter des requêtes lourdes portant sur l'ensemble des champs des index.

Ce type de requêtes peut être un trou de sécurité permettant à des utilisateurs d'accéder à des données confidentielles ou de faire tomber le cluster.

=> En production, on interdit généralement ce type d'API au profit de DSL



Recherche vide

GET /_search

Retourne tous les documents de tous les index du cluster

Réponse

```
"hits" : {
  "total" : 14,
  "hits" : [ {
    "_index": "us",
    "_type": "tweet",
    "_id": "7",
    _score": 1,
    " source": {
      "date": "2014-09-17",
      "name": "John Smith",
      "tweet": "The Query DSL is really powerful and flexible",
      "user_id": 2
       ... RESULTS REMOVED ... ],
  "max score" : 1
}, tooks : 4,
  "_shards" : {
    "failed" : 0,
    "successful" : 10,
    "total" : 10
  },
  "timed_out" : false
```



Champs de la réponse

hits: Le nombre de document qui répondent à la requête, suivi d'un tableau contenant l'intégralité des 10 premiers documents. Chaque document a un élément _score qui indique sa pertinence. Par défaut, les documents sont triés par pertinence

took : Le nombre de millisecondes pris par la requête

shards: Le nombre total de shards ayant pris part à la requête. Certains peuvent avoir échoués

timeout : Indique si la requête est tombée en timeout. Il faut avoir lancé une requête de type : GET /_search?timeout=10ms



Limitation à un index, un type

_search : Tous les index, tous les types
/gb/_search : Tous les types de l'index gb
/gb,us/_search : Tous les types de l'index gb et us
/g*,u*/_search : Tous les types des index
commençant par g ou u
/gb/user/_search : Tous les documents de type
user dans l'index

/gb,us/user,tweet/_search: Tous les documents de type user ou tweet présents dans les index gb et us /_all/user,tweet/_search: Tous les documents de type user ou tweet présents dans tous les index



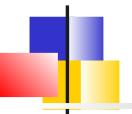
Pagination

Par défaut, seul les 10 premiers documents sont retournés.

ELS accepte les paramètres from et size pour contrôler la pagination :

- size : indique le nombre de documents devant être retournés
- from : indique l'indice du premier document retourné

Paramètre q



L'API search lite prend le paramètre q qui indique la chaîne de requête dans la syntaxe lucene

La chaîne est parsée en une série de

- Termes : (Mot ou phrase)
- Et d'opérateurs (AND/OR)

La syntaxe support :

- Les caractères joker et les expressions régulières
- Le regroupement (parenthèses)
- Les opérateurs booléens (OR par défaut, + : AND, : AND NOT)
- Les intervalles : Ex : [1 TO 5]
- Les opérateurs de comparaison



Syntaxe Lucene

```
Recherche d'un terme sur le champ par défaut :
```

elastic

Sur un champ particulier

title:elastic

Recherche d'une phrase

title: "elastic search"

Combinaison opérateur par défaut OR

elastic search

elastic OR search

elastic AND search

+elastic +search

elastic NOT search

elastic -search

(+elastic +search) OR kibana



Syntaxe Lucene (2)

Recherche par préfixe:

ela*

elas?tic

Recherche de proximité

"elastic search"~5

elastik~2

Recherche sur un intervalle

[10 TO 20]

{10 T0 20}

Boosting

elastic^2 search



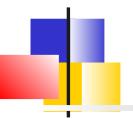
Exemples search lite

GET /_search?q=tweet:elasticsearch
Tous les documents de type tweet dont le
champ full text match « elasticsearch »

+name:john +tweet:mary

Tous les documents dont le champ full-text name correspond à « john » et le champ tweet à « mary »

Le préfixe – indique des conditions qui ne doivent pas matcher



Champ _all

Lors de l'indexation d'un document, ELS concatène toutes les valeurs de type string dans un champ full-text nommé _all

C'est ce champ qui est utilisé si la requête ne précise pas de champ

GET /_search?q=mary

Si le champ _all n'est pas utile, il est possible de le désactiver



Exemple plus complexe

La recherche suivante utilise les critères suivants :

- Le champ name contient « mary » ou « john »
- La date est plus grande que « 2014-09-10 »
- Le champ _all contient soit les mots « aggregations » ou « geo »

```
+name:(mary john) +date:>2014-09-10 + (aggregations geo)
```

Voir doc complète :

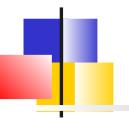
https://www.elastic.co/guide/en/elasticsearch/reference/current/query-dsl-query-string-query.html#query-string-syntax



Autres paramètres de la query string

Les autres paramètres disponibles sont :

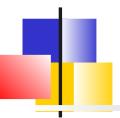
- df: Le champ par défaut, utilisé lorsque aucun champ n'est précisé dans la requête
- default_operator (AND/OR) : L'opérateur par défaut. Par défaut OR
- explain: Une explication du score ou de l'erreur pour chaque hit
- _source : false pour désactiver la récupération du champ source.
 - Possibilité de ne récupérer que des parties du document avec _source_include & _source_exclude
- sort : Le tri. Par exemple title:desc,_score
- timeout : Timeout pour la recherche. A l'expiration du timeout, les hits trouvés sont retournés



Mapping et Analyseurs

Types simples et champs full text

Contrôler le mapping Mapping dynamique Analyseur custom Réindexation



Types simples supportés

ELS supporte :

- Les chaînes de caractères : string
 - text ou keyword (pas analysé)
- Les numériques : byte , short , integer , long, float , double, token_count
- Les booléens : boolean
- Les dates : date
- Les octets : binary
- Les intervalles : integer_range, float_range, long_range, double_range, date_range
- Les adresses IP : IPV4 ou IPV6
- Les données de géo-localisation : geo_point, geo_shape
- Un requête (structure JSON) : percolator



Valeur exacte ou full-text

Les chaînes de caractère indexées par ELS peuvent être de deux types :

- keyword : La valeur est prise telle quelle, des opérateurs de type <u>filtre</u> peuvent être utilisés lors de la recherche Foo! = foo
- text: La valeur est analysée et découpée en termes ou token. Des opérateurs de recherche <u>full-text</u> peuvent être utilisés lors des recherche. Cela concerne des données en langage naturel



Index inversé

Afin d'accélérer les recherches sur les champs *text*, ELS utilise une structure de donnée nommée **index inversé**

Cela consiste en une liste de mots unique où chaque mot est associé aux documents dans lequel il apparaît.

La liste de termes est constituée après une phase d'analyse du champ texte originel.



Exemple

	Α	В
1	term	docs
2	pizza	3, 5
3	solr	2
4	lucene	2, 3
5	sourcesense	2, 4
6	paris	1, 10
7	tomorrow	1, 2, 4, 10
8	caffè	3, 5
9	big	6
10	brown	6
11	fox	6
12	jump	6
13	the	1, 2, 4, 5, 6, 8, 9



Étapes de l'analyse

Les *analyseurs* transforment un texte en un flux de "termes".

Ils sont constitués de 3 types de composants

- Les filtres de caractères préparent le texte en effectuant du remplacement de caractères (& devient et) ou en supprimant (suppression des balises HTML)
- Les tokenizers splittent un texte en une suite d'unité lexicale : les termes
- Les filtres prend en entrée un flux de terme et le transforme en un autre flux de terme

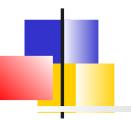


Analyseurs prédéfinis

- ELS propose des analyseurs directement utilisables :
 - **Analyseur Standard**: C'est l'analyseur par défaut. Le meilleur choix lorsque le texte est dans des langues diverses. Il consiste à :
 - Séparer le texte en mots
 - Supprime la ponctuation
 - Passe tous les mots en minuscule
 - Analyseur simple : Sépare le texte en token de 2 lettres minimum puis passe en minuscule
 - **Analyseur d'espace** : Sépare le texte en fonction des espaces
 - Analyseurs de langues : Ce sont des analyseurs spécifiques à la langue. Ils incluent les « stop words » (enlève les mots les plus courant) et extrait la racine d'un mot. C'est le meilleur choix si l'index est en une seule langue

Test des analyseurs

```
GET / analyze?analyzer=standard
Text to analyze
<u>Réponse</u>:
"tokens": [ {
  "token": "text",
  "start offset": 0,
  "end offset":4,
  "type": "<ALPHANUM>",
  "position": 1
  "token": "to",
  "start offset": 5,
  "end offset": 7,
  "type": "<ALPHANUM>",
  "position": 2
  "token": "analyze",
  "start offset": 8,
  "end offset": 15,
  "type":"<ALPHANUM>",
  "position": 3
} ] }
```



Mapping et Analyseurs

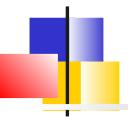
Types simples et champs full text

Contrôler le mapping

Mapping dynamique

Analyseur custom

Réindexation



Mapping

ELS est capable de générer dynamiquement le mapping

Il devine alors le type des champs

On peut voir le mapping d'un index par :

GET /gb/_mapping



Réponse _mapping

```
{ "gb": {
  "mappings": {
    "tweet": {
      "properties": {
        "date": {
         "type": "date",
         "format": "dateOptionalTime"
         },
         "name": {
           "type": "text"
         },
         "tweet": {
          "type": "text"
         "user_id":
          "type": "long"
```



Type et Mapping

Un mapping définit pour chaque champ d'un document

- Le type de donnée
- Si champ de type text, comment ELS analyse le champ
- Les méta-données associées



Comportement par défaut

Lorsque ELS détecte un nouveau champ *String* dans un type de document, il le configure automatiquement comme 2 champs :

- 1 champ text utilisant l'analyseur standard.
- 1 champ keyword nommé <field_name>.keyword

Si ce n'est pas le comportement voulu, il faut explicitement spécifier le **mapping** lors de la création de l'index



Mapping personnalisé

Un mapping personnalisé permet (entre autre) de :

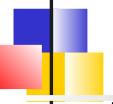
- Faire une distinction entre les champs string de type full-text ou valeur exacte
- Utiliser des analyseurs spécifiques
- Optimiser un champ pour le matching partiel (voir + loin)
- Spécifier des formats de dates personnalisés
- Définir plusieurs types et/ou analyseurs pour le même champ



Spécification du mapping

On peut spécifier le mapping :

- Lors de la création d'un index
- Lors de l'ajout d'un nouveau type
- Lors de l'ajout d'un nouveau champ dans un type existant
 On ne peut pas modifier un champ déjà indexé



Exemple (création)

```
PUT /gb
 "settings": { ... any settings : shards, replica,... },
  "mappings": {
      "properties" : {
        "tweet" : {
          "type" : "text",
          "analyzer": "english"
        },
        "date" : {
          "type" : "date"
        },
        "name" : {
          "type" : "keyword"
        },
         "user_id" : {
         "type" : "long"
} } }
```



Exemple (Ajout)

```
PUT /gb/ mapping/tweet
  "properties" : {
    "tag" : {
      "type" : "keyword"
```

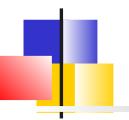


Double mapping

Un besoin relativement courant est d'indexer un même champ de plusieurs façons . L'attribut *fields* permet de définir des sous-champs ayant une autre stratégie d'indexation

```
"tweet": {
"type": "string",
"analyzer": "english",
"fields": {
    "raw": {
       "type": "keyword",
     }
} }
```

Le nouveau sous-champ tweet.raw n'est pas analysé



Mapping et Analyseurs

Types simples et champs full text Contrôler le mapping **Mapping dynamique** Analyseur custom Réindexation

Dynamic Mapping



La détection de type lors de l'ajout d'un nouveau champ est appelée le *dynamic mapping*

Les règles de détection peuvent être customisées via 2 moyens :

- L'activation ou la désactivation du dynamic mapping
- L'édition des gabarits dynamique (dynamic templates) spécifiant les règles de mapping pour les nouveaux champs

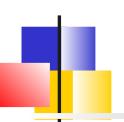
Activation/Désactivation du dynamic mapping

La propriété **dynamic** permet de spécifier le comportement du dynamic mapping :

- true (défaut) : Chaque nouveau champ est automatiquement ajouté
- false : Tout nouveau champ est ignoré
- strict : Tout nouveau champ lève une exception

La spécification de *dynamic* peut s'effectuer sur l'objet racine ou sur une propriété particulière

```
PUT /my_index
{
"mappings": {
    "my_type": {
        "dynamic": "strict",
        "properties": {
            "title": { "type": "string"},
            "stash": { "type": "object", "dynamic": true }
     }
}} }ynamic
```



Règles de détection par défaut

Par défaut, en fonction du type JSON, ElasticSearch applique des correspondances :

null : Pas d'ajout de champ

true ou **false** : Champ boolean

Point flottant: Champ float

integer : Champ *long*

object : champ *object*

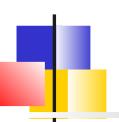
array : Dépend de la première valeur non nulle du tableau

String:

- Soit un champ date (Possibilité de configurer les formats de détection)
- Soit un double ou long (Possibilité de configurer les formats de détection)
- Soit un champ text avec un sous-champ keyword.

Exemple : Configuration des formats de détection

```
PUT my_index
{
    "mappings": {
        "dynamic_date_formats": ["MM/dd/yyyy"],
        "numeric_detection": true
    }
}
```



Règles de détection

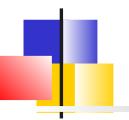
Les règles de détction permettent de définir un mapping en fonction :

- Du datatype détecté par ELS (propriété match_mapping_type).
- Du nom du champ (propriétés match, unmatch ou match pattern).
- Du chemin complet du champ (propriétés path_match et path_unmatch).

Le nom d'origine du champ {name} et le type détecté {dynamic_type} peuvent être utilisés comme variable lors de la spécification des règles

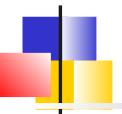
Exemple : Ajouts de règles custom

```
PUT my index
{ "mappings": { "my type": {
      "dynamic templates": [
       { "integers": {
           "match_mapping_type": "long",
           "mapping": {
             "type": "integer"
       } } } ,
       { "strings": {
           "match mapping type": "string",
           "mapping": {
             "type": "text",
             "fields": {
               "raw": {
                 "type": "keyword",
                 "ignore above": 256
```



Mapping et Analyseurs

Types simples et champs full text Contrôler le mapping Mapping dynamique Analyseurs custom Réindexation



Analyseur explicite

- Lorsque ELS détecte un nouveau champ String dans un type de document,
 - il le configure automatiquement comme champ full-text et applique l'analyseur standard.
 - Ajoute un sous-champ non analysé (type keyword)
- Si ce n'est pas le comportement voulu, il faut explicitement spécifier le mapping pour le type de document



Analyseurs

Les composants de l'analyseur standard sont :

- Le <u>filtre de token standard</u> (qui ne fait rien)
- Le <u>tokenizer standard</u> qui sépare sur les frontières de mots
- Le filtre <u>lowercase</u> qui passe tout en minuscule

Il est possible de surcharger cette configuration par défaut en ajoutant un filtre ou en remplaçant un existant



Création par surcharge

Dans l'exemple suivant, un nouvel analyseur fr_std pour l'index french_docs est créé. Il utilise la liste prédéfinie des stopwords français :



Création complète

Il est possible de créer ses propres analyseurs en combinant des filtres de caractères, un tokenizer et des filtres de tokens :

```
- 0 ou n : Filtres de caractères
- 1 : tokenizer
- 0 ou n : Filtre de tokens

PUT /my_index
{
   "settings": {
        "analysis": {
            "char_filter": { ... custom character filters ... },
            "tokenizer": { ... custom tokenizers ... },
            "filter": { ... custom tokenizers ... },
            "analyzer": { ... custom analyzers ... }
} }
}
```

Exemple

```
PUT /my index
"settings": {
  "analysis": {
   "char_filter": {
     "& to and": {
       "type": "mapping",
        "mappings": [ "&=> and "]
       }}, "filter": {
        "my_stopwords": {
          "type": "stop",
          "stopwords": [ "the", "a" ]
        }},
        "analyzer": {
          "my_analyzer": {
            "type": "custom",
             "char_filter": [ "html_strip", "&_to_and" ],
             "tokenizer": "standard",
             "filter": [ "lowercase", "my_stopwords" ]
}}
}}}
```



Affectation à un index

Il faut ensuite associer l'analyseur à un champ string PUT /my_index/_mapping "properties": { "title": { "type":"text", "analyzer": "my_analyzer"



Analyseurs prédéfinis

Elasticsearch fournit des analyseurs pré-définis pouvant être utilisés directement :

- Standard (par défaut) : Sépare en mot, enlève la ponctuation, passe en minuscule, supporte les stop words
- Simple : Sépare en token dés qu'il trouve un caractère qui n'est pas une lettre. Passe en minuscule
- Whitespace : Se base sur les espaces pour la tokenization. Ne passe pas en minuscule
- **Stop**: Comme l'analyseur simple avec du support pour les stop words.
- **Keyword**: Ne fait rien. Prend le texte tel quel
- Pattern: Utilise une expression régulière pour la tokenization. Passe en minuscule et supporte les stop words.
- Language : english, french, ...
- Fingerprint : Crée une empreinte du document pouvant être utilisé pour tester la duplication.



Filtres fournis

ELS fournit de nombreux filtres permettant de mettre au point des analyseurs personnalisés. Citons :

- Length Token: Suppression de mots trop courts ou trop longs
- N-Gram et Edge N-Gram : Analyzeur permettant d'accélérer les suggestion de recherche
- Stemming filters : Algorithme permettant d'extraire la racine d'un mot
- **Phonetic filters** : Représentation phonétique des mots
- **Synonym**: Correspondance de mots
- Keep Word : Le contraire de stop words
- Limit Token Count : Limite le nombre de tokens associés à un document
- Elison Token : Gestion des apostrophes (français)



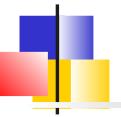
Utilisation de synonymes

Les synonymes peuvent être utilisés pour fusionner des mots qui ont quasiment le même sens.

Ex : joli, mignon, beau

Ils peuvent également être utilisés afin de rendre un mot plus générique.

 Par exemple, oiseau peut être utilisé comme synonyme à pigeon, moineau, ...



Ajout d'un filtre synonyme



3 utilisations

Le remplacement de synonyme peut se faire de 3 façons :

- Expansion simple : Si un des termes est rencontré, il est remplacé par tous les synonymes listés
 "jump,leap,hop"
- Contraction simple : un des termes rencontré est remplacé par un synonyme
 "leap,hop => jump"
- Expansion générique : un terme est remplacé par plusieurs synonymes
 "puppy => puppy,dog,pet"



Mapping et Analyseurs

Types simples et champs full text Contrôler le mapping Mapping dynamique Analyseurs custom Réindexation



Réindexation

Il n'est pas possible d'effectuer certains changements à posteriori sur un index. (ajout d'analyseur par exemple)

Pour réorganiser un index, la seule solution consiste à réindexer, i.e. créer un nouvel index avec la nouvelle configuration et copier tous les documents du vieil index vers le nouveau.

Cela s'effectue généralement avec une recherche de type « scan and scroll » et l'API « bulk » pour grouper les mises à jour



Utilisation

L'utilisation s'effectue en positionnant les paramètres search_type et scroll qui précise la durée pendant laquelle le scroll est ouvert

```
GET /old_index/_search?scroll=lm // 1 minute
{
    "query": { "match_all": {}}, "size": 1000
}
La réponse ne contient pas de hit mais un _scroll_id (Base 64 string) qui peut être utilisé pour récupérer le premier lot de documents
POST /_search/scroll?scroll=lm
c2Nhbjs10zEx0DpRNV9aY1VyUVM4U0NMd2pjWlJ3YWlB0zEx0TpRNV9aY1VyUVM4U0
NMd2pjWlJ3YWlB0zExNjpRNV9aY1VyUVM4U0NMd2pjWlJ3YWlB0zExNzpRNV9aY1Vy
UVM4U0NMd2pjWlJ3YWlB0zEyMDpRNV9aY1VyUVM4U0NMd2pjWlJ3YWlB0zE7dG90YW
XfaGl0czox0w==
La réponse contient un autre _scroll_id permettant d'obtenir le lot suivant. Il
```

La réponse contient un autre <u>scrollid</u> permettant d'obtenir le lot suivant. Il faut alors répéter les requêtes jusqu'à ce qu'il n'y ait plus de documents



API reindex

L'API _reindex consiste à recopier les documents d'un index vers un autre index.

L'index cible peut avoir une configuration différente que l'index source (réplique, shard, mapping)

```
POST _reindex
{
    "source": {
        "index": "twitter"
    },
    "dest": {
        "index": "new_twitter"
    }
}
```



API reindex

Il est possible de filtrer les documents recopiés et même d'interroger un cluster distant.



Recherche avec DSL

Syntaxe DSL

Principaux opérateurs Tri et pertinence Contrôle du score



Introduction DSL

Les recherches avec un corps de requête offrent plus de fonctionnalités qu'une recherche simple.

En particulier, elles permettent :

- De combiner des clauses de requêtes plus facilement
- D'influencer le score
- De mettre en surbrillance des parties du résultat
- D'agréger des sous-ensemble de résultats
- De retourner des suggestions à l'utilisateur

— ...



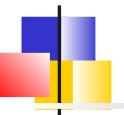
GET ou POST

La RFC 7231 qui traite de la sémantique HTTP ne définit pas des requêtes GET avec un corps

- => Seuls certains serveurs HTTP le supportent

ELS préfère cependant utiliser le verbe *GET* car cela décrit mieux l'action de récupération de documents

Cependant, afin que tout type de serveur HTTP puisse être mis en frontal de ELS, les requêtes GET avec un corps peuvent également être effectuées avec le verbe **POST**



Recherches vides

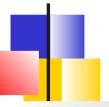
```
GET /_search
{}
GET /index_2014*/type1,type2/_search
{}
GET /_search
"from": 30,
"size": 10
```



Paramètre query

Pour utiliser DSL, il faut passer une requête dans le paramètre *query* :

```
GET /_search
{ "query": YOUR_QUERY_HERE }
```



Structure de la clause Query

```
QUERY_NAME/OPERATOR: {
    ARGUMENT: VALUE,
    ARGUMENT: VALUE,...
Exemple:
GET /_search
  "query": {
    "match": { "tweet": "elasticsearch" }
```



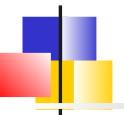
Principe DSL

DSL peut être vu comme un arbre syntaxique qui contient :

- Des clauses de requête **feuille**.
 Elles correspondent à un type de requête (*match*, *term*, *range*) s'appliquant à un champ. Elle peuvent s'exécuter seules
- Des clauses composées.
 Elles combinent d'autres clauses (feuille ou composée) avec des opérateurs logiques (bool, dis_max) ou altèrent leurs comportements (constant score)

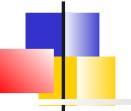
De plus, les clauses peuvent être utilisées dans 2 contextes différents qui modifient leur comportement

- Contexte requête ou full-text
- Contexte filtre



Exemple Combinaison

```
{
"bool": {
    "must": { "match": { "tweet": "elasticsearch" }},
    "must_not": { "match": { "name": "mary" }},
    "should": { "match": { "tweet": "full text" }}
}
```



Ex: Combinaison de combinaisons

```
"bool": {
  "must": { "match": { "email": "business
opportunity" }},
  "should": [
    { "match": { "starred": true }},
    { "bool": {
      "must": { "folder": "inbox" }},
      "must not": { "spam": true }}
    }} ],
    "minimum should match": 1
}}
```



Distinction entre requête et filtre

DSL permet d'exprimer 2 types de requête

- Les filtres sont utilisés pour les champs contenant des valeurs exactes.
 Leur résultat est de type booléen, i.e. un document satisfait un filtre ou pas
- Les recherches calculent un score de pertinence pour chaque document trouvé.
 Le résultat est trié par le score de pertinence



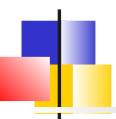
Activation des contextes

Le contexte *recherche* est activée dés lors qu'une clause est fournie en paramètre au mot-clé *query*

Le contexte filtre est activée dés lors qu'une clause est fournie en paramètre au mot-clé *filter* ou *must_not*



Exemple



Performance filtre/recherche

La sortie de la plupart des filtres est une liste simple de documents qui satisfont le filtre. Le résultat peut être facilement caché par ELS

Les recherches doivent trouver les documents correspondant au mots-clés et en plus calculer le score de pertinence.

- => Les recherches sont donc plus lourdes que les filtres et sont plus difficilement cachable
- => L'objectif des filtres est de réduire le nombre de documents devant être examinés par la recherche



Recherche avec DSL

Syntaxe DSL

Principaux opérateurs

Tri et pertinence

Contrôle du score



Opérateur de combinaison

bool: Permet de combiner des clauses avec :

- must équivalent à ET avec contribution au score
- filter idem must mais ne contribue pas au score
- must_not équivalent à NOT
- should équivalent à OU



Types de recherche

Les requêtes textuelles peuvent être classifiées en 2 :

- Les requêtes n'effectuant pas d'analyse et opérant sur un terme unique (term, fuzzy).
- Les requêtes qui appliquent l'analyseur sur les termes recherchés correspondant au champ recherché (match, query_string).



Opérateurs sans analyse

```
term : Utilisé pour filtrer des valeurs exactes :
{ "term": { "age": 26 }}
terms : Permet de spécifier plusieurs valeurs :
{ "terms": { "tag": [ "search", "full text",
"nosql" ] }}
range : Permet de spécifier un intervalle de date ou
nombre:
{ "range": { "age": { "gte": 20, "lt": 30
} } }
exists et missing : Permet de tester si un document
contient ou pas un champ
{ "exists": {    "field": "title" }}
```



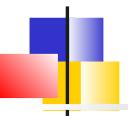
match_all, match_none

La recherche *match_all* retourne tous les documents. C'est la recherche par défaut si aucune recherche n'est spécifiée Tous les documents sont considérés également pertinent, ils reçoivent un *_score* de 1

```
{ "match_all": {}}
```

Le contraire de *match_all* est *match_none* qui ne retourne aucun document.

```
{ "match_none": { }}
```



match

La recherche *match* est la recherche standard pour effectuer une recherche exacte ou full-text sur presque tous les champs.

- Si la requête porte sur un champ full-text, il analyse la chaîne de recherche en utilisant le même analyseur que le champ,
- si la recherche porte sur un champ à valeur exacte, il recherche pour la valeur exacte

```
{ "match": { "tweet": "About Search" } }
```



OR par défaut

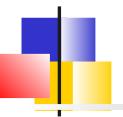
match est une requête booléene qui par défaut analyse les mots passés en paramètres et construit une requête de type OR. Elle peut être composée de :

- operator (and/or) :
- minimum_should_match : le nombre de clauses devant matcher
- analyzer : l'analyseur à utiliser pour la chaîne de recherche
- lenient : Pour ignorer les erreurs de types de données



Exemple

```
GET /_search
    "query": {
        "match" : {
            "message" : {
                "query" : "this is a test",
                "operator" : "and"
```



Contrôler la combinaison

Documents contenant 75 % des mots précisés



multi match

La requête *multi_match* permet d'exécuter la même requête sur plusieurs champs :

```
{"multi_match": { "query": "full text search", "fields":
[ "title", "body" ] } }
```

Les caractères joker peuvent être utilisés pour les champs Les champs peuvent être boostés avec la notation ^

```
GET /_search
{
    "query": {
        "multi_match" : {
            "query" : "this is a test",
            "fields" : [ "subject^3", "text*" ]
        }
    }
}
```

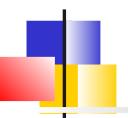


query_string

Les requêtes de types **query_string** utilise un parseur pour comprendre la chaîne de requêtes. (le même que pour la recherche lite)

Il a de nombreux paramètres (default_field, analyzer, ...)

```
GET /_search
{
    "query": {
        "query_string" : {
            "default_field" : "content",
            "query" : "title:(quick OR brown)"
        }
    }
}
```



simple_query_string

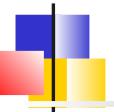
L'opérateur **simple_query_string** permet de ne pas provoquer d'erreur de parsing de la requête de recherche.

Il peut être utilisé directement avec la saisie d'un utilisateur

Il prend la syntaxe simplifiée :

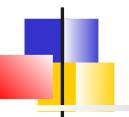
- + pour AND
- | pour OR
- pour la négation

— ...



Validation des requêtes

```
GET /gb/tweet/_validate/query?explain
{ "query": { "tweet" : { "match" : "really powerful" } }
•••
"valid" : false,
"_shards" : { ... },
"explanations" : [ {
  "index" : "gb",
  "valid" : false,
  "error" : "org.elasticsearch.index.query.QueryParsingException:
[gb] No query registered for [tweet]"
} ]
```



Recherche avec DSL

Syntaxe DSL
Principaux opérateurs **Tri et pertinence**Contrôle du score



Tri selon un champ

Lors de requêtes de type filtre, il peut être intéressant de fixer le critère de tri.

```
Cela s'effectue via le paramètre sort

GET /_search
{
    "query" : {
        "bool" : {
            "filter" : { "term" : { "user_id" : 1 }}
        }
     }, "sort": { "date": { "order": "desc" }}
}
```



Réponse

Dans la réponse, la propriété <u>score</u> n'est alors pas calculée et la valeur du champ de tri est précisée pour chaque document

```
"hits" : {
    "total" : 6,
    "max_score" : null,
    "hits" : [ {
        "_index" : "us",
        "_type" : "tweet",
        "_id" : "14",
        "_score" : null,
        "_source" : {
        "date": "2014-09-24",
        ...
    },"sort" : [ 14115168000000 ]
},
...
}
```



Plusieurs critères de tri

Il est possible de combiner un critère de tri avec un autre critère ou le score. Attention l'ordre est important



Tri sur les champs multivalués

Il est possible d'utiliser une fonction d'agrégation pour trier des champs multivalués (min, max, sum, avg, ...)

```
"sort": {
    "dates": {
        "order": "asc",
        "mode": "min"
    }
}
```



Pertinence

Le score de chaque document est représenté par un nombre à virgule (_score). Plus ce chiffre est élevé, plus le document est pertinent.

L'algorithme utilisé par ELS est dénommé **term frequency**/

inverse document frequency, ou TF/IDF. Il prend en compte les facteurs suivants :

- La fréquence du terme : combien de fois apparaît le terme dans le champ
- La fréquence inverse au niveau document : Combien de fois apparaît le terme dans l'index ? Plus le terme apparaît moins il a de poids.
- La longueur du champ normalisée : Plus le champ est long, moins les mots du document sont pertinents

En fonction du type de requête (requête floue, ...) d'autres facteurs peuvent influencer le score



Explication de la pertinence

```
ELS permet d'obtenir une explication du score grâce au paramètre explain
GET /_search?explain
{ "query"
: { "match" : { "tweet" : "honeymoon" }}
Le paramètre explain peut également être utilisé pour comprendre pourquoi
un document match ou pas.
GET /us/tweet/12/ explain
"query" : {
  "bool" : {
    "filter" : { "term" : { "user id" : 2 }},
    "must" : { "match" : { "tweet" : "honeymoon" }}
} } }
```



Réponse

```
" explanation": {
  "description": "weight(tweet:honeymoon in 0)
  [PerFieldSimilarity], result of:",
  "value": 0.076713204,
  "details": [ {
    "description": "fieldWeight in 0, product of:",
    "value": 0.076713204,
    "details": [ {
      "description": "tf(freq=1.0), with freq of:",
      "value": 1,
      "details": [ {
        "description": "termFreq=1.0",
        "value": 1
     } ]
   }, {
      "description": "idf(docFreq=1, maxDocs=1)",
      "value": 0.30685282
   }, {
       "description": "fieldNorm(doc=0)",
       "value": 0.25,
    } ]
} ] }
```

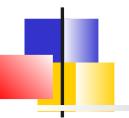


Regroupement

Le paramètre *collapse* permet de regrouper les résultats par la valeur d'un champ.

ELS ne retourne alors qu'un document par valeur distincte du groupe.

Ce regroupement est effectué après le tri.



Recherche avec DSL

Syntaxe DSL
Principaux opérateurs
Tri et pertinence
Contrôle du score



Cas de multi match

Le paramètre **type** précise le fonctionnement de l'opérateur et le calcul du score.

- best_fields (défaut) : Trouve les documents qui match avec un des champs mais utilise le meilleur champ pour affecter le score
- most_fields : Combine le score de chaque champ
- cross_fields : Concatène tous les champs et utilise le même analyseur
- phrase : Utilise un match_phrase sur chaque champ et combine le score de chaque champ
- phrase_prefix : Utilise un match_phrase_prefix sur chaque champ et combine le score de chaque champ



multi match

La requête *multi_match* permet de facilement exécuter la même requête sur plusieurs champs. Le caractère joker peut être utilisé ainsi que le boost individuel

```
"multi_match": {
"query": "Quick brown fox",
"type": "best_fields",
"fields": [ "*_title^2", "body" ],
"tie_breaker": 0.3,
"minimum_should_match": "30%"
} }
```



Cas de bool

Le calcul de la pertinence s'effectue en additionnant le score de chaque clause *must* ou *should* et en divisant par 4



Boosting clause

Il est possible de donner plus de poids à une clause particulière en utilisant le paramètre **boost**

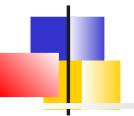
```
GET /_search
{
"query": { "bool": {
    "must": { "match": {
        "content": { "query": "full text search", "operator": "and" }}},
        "should": { "match": {
            "content": { "query": "Elasticsearch", "boost": 3 }}}
} }}
```



Opérateur boosting

L'opérateur **boosting** permet d'indiquer une clause qui réduit le score des documents qui matchent

```
GET /_search
{
    "query": {
        "boosting" : {
            "rerm" : {"text" : "apple"}
        },
        "negative" : {
            "term" : { "text" : "pie tart fruit crumble tree" }
        },
        "negative_boost" : 0.5 // requis le malus au document qui matche
    }
}
```



dis max

Au lieu de combiner les requêtes via *bool*, il peut être plus pertinent d'utiliser *dis_max*

dis_max est un OR mais le calcul de la pertinence diffère

Disjunction Max Query signifie : retourne les documents qui matchent une des requêtes et retourne le score de la requête qui matche le mieux



tie breaker

Il est également possible de tenir compte des autres requêtes qui match en leur donnant une plus petite importance.

C'est le paramètre *tie_breaker*

Le calcul du score est alors effectué comme suit :

- 1. Prendre le score de la meilleure clause .
- 2. Multiplier le score de chaque autres clauses qui matchent par le tie_breaker.
- 3. Les ajouter et les normaliser



Indexation multiple

Une technique très courante pour affiner la pertinence de documents et d'indexer plusieurs fois le même champ en utilisant des analyseurs différents.

Ensuite, une analyseur est utilisé pour trouver le plus de documents possibles, les autres pour différencier la pertinence des documents retournés.



Indexation multiple

```
PUT /my index
{ "settings": { "number_of_shards": 1 },
"mappings": { "my type": {
  "properties": {
  "title": {"type": "text", "analyzer": "english",
    "fields": {
      "std": { "type": "text", "analyzer":
"standard" }
```



Utilisation

Utilisation du même champ indexé plusieurs fois

```
GET /my_index/_search
{
  "query": {
  "multi_match": {
  "query": "jumping rabbits",
  "type": "most_fields", // bool OR plutot que dis_max
  "fields": [ "title^10", "title.std" ]
}
}
```



Indexation multiple

L'indexation multiple est également souvent utilisée pour concaténer dans un autre champ, plusieurs champs (variante du _all).



cross fields

Si on a oublié d'effectuer une indexation multiple, on peut indiquer lors d'une requête multi-champs que l'on veut traiter ces champs comme un seul champ.

```
GET /books/_search
{
  "query": {
  "multi_match": {
     "query": "peter smith",
     "type": "cross_fields",
     "fields": [ "last_name", "first_name" ]
} } }
```



Recherches avancées

Recherche avec préfixe

Recherche phrase Recherche floue Surbrillance Agrégations Géo-localisation



Matching partiel

Le matching partiel permet aux utilisateurs de spécifier une portion du terme qu'il recherche

Les cas d'utilisation courant sont :

- Le matching de codes postaux, de numéro de série ou d'autre valeur not_analyzed qui démarre avec un préfixe particulier ou même une expression régulière
- Recherche à la volée : des recherches effectuées à chaque caractère saisie permettant de faire des suggestions à l'utilisateur
- Le matching dans des langages comme l'allemand qui contiennent de long nom composés



Filtre *prefix*

Le filtre *prefix* est une recherche s''effectuant sur le terme. Il n'analyse pas la chaîne de recherche et assume que l'on a fourni le préfixe exact

```
GET /my_index/address/_search
{
"query": {
  "prefix": { "postcode": "W1" }
}
}
```



Wildcard et regexp

Les recherche *wildcard* ou *regexp* sont similaires à *prefix* mais permet d'utiliser des caractère joker ou des expressions régulières

```
GET /my_index/address/_search
{
  "query": {
    "wildcard": { "postcode": "W?F*HW" }
}
GET /my_index/address/_search
{
  "query": {
  "regexp": { "postcode": "W[0-9].+" }
}
}
```



Indexation pour l'autocomplétion

L'idée est d'indexer les débuts de mots de chaque terme Cela peut être effectué via un filtre particulier edge ngram

Pour chaque terme, il crée *n tokens* de taille minimum 1 et de maximum 20. Les tokens sont le différents préfixes du terme.



Recherches avancées

Recherche avec préfixe
Recherche phrase
Recherche floue
Surbrillance
Agrégations
Géo-localisation



match_phrase

La recherche *match_phrase* analyse la chaîne pour produire une liste de termes mais ne garde que les documents qui contient tous les termes dans le même position.

```
GET /my_index/my_type/_search
{
   "query": {
     "match_phrase": { "title": "quick brown fox" }
}}
```

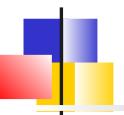


Proximité avec slop

Il est possible d'introduire de la flexibilité au phrase matching en utilisant le paramètre **slop** qui indique à quelle distance les termes peuvent se trouver.

Cependant, les documents ayant ces termes les plus rapprochés auront une meilleur pertinence.

```
GET /my_index/my_type/_search
{
"query": {
   "match_phrase": {
    "title": {
        "query": "quick fox",
        "slop": 20 // ~ distance en mots
}    } } }
```



match phrase prefix

La recherche *match_phrase_prefix* se comporte comme *match_phrase*, sauf qu'il traite le dernier mot comme un préfixe Il est possible de limiter le nombre d'expansions en positionnant *max_expansions*

```
"match_phrase_prefix" : {
"brand" : {
    "query": "johnnie walker bl",
    "max_expansions": 50
}
}
```



Recherches avancées

Recherche avec préfixe Recherche phrase Recherche floue Surbrillance Agrégations Géo-localisation



Introduction

Pour augmenter les résultats d'une recherche en langage naturel, plusieurs techniques sont utilisées :

- Supprimer les diacritiques comme ´, ^ , et ¨. Ainsi « rôle » match « role »
- Supprimer les distinctions entre singulier et pluriel, les conjugaisons en normalisant chaque mot à sa racine (stemming)
- Supprimer les mots trop communs (stopwords) comme « et » « le » « un »
- Inclure des synonymes afin que « UE » puisse matcher « Communauté européenne »
- Vérifier les fautes de typo ou travailler sur la phonétique

Analyseur dédié à une langue

ELS fournit des analyseurs dédiés aux langues les plus courantes

Ces analyseurs effectuent en général 4 étapes :

- Sépare le texte en mots
- Passe chaque mot en minuscule
- Supprime les mots communs (stopwords)
- Remplace le terme par leur racine (Stem)

En fonction des langues, d'autres filtres peuvent être appliqués :

 Ex en FR, Elision Filter qui supprime les apostrophes et accents



Gestion des typos

Pour gérer les erreurs de typo, les technique des *matching flou (Fuzzy matching)* peuvent être utilisées.

Ces techniques s'appuient sur la distance de Levenshtein, qui mesure le nombre d'éditions d'un simple caractère nécessaires pour passer d'un mot à un autre

- La plupart des erreurs de typo ou de mauvaise orthographe ont une distance de 1.
 - => Ainsi, 80 % des erreurs pourraient être corrigés avec l'édition d'un seul caractère

Il est possible lors d'une requête de positionner le paramètre **fuzziness** qui donne donc la tolérance en distance de Levenshtein.

Ce paramètre peut également être positionné à la valeur AUTO :

- 0 pour les chaîne de 1 ou 2 caractères
- 1 pour les chaîne de 3, 4 ou 5 caractères
- 2 pour les chaîne de plus de 5 caractères

Attention: Pas de stemmer avec le mode fuzzy!



Requête fuzzy

La recherche fuzzy est équivalent à une recherche par terme

```
GET /my_index/my_type/_search
{
"query": {
   "fuzzy": {"text": "surprize" }
} }
```

2 paramètres peuvent être utilisées pour limiter l'impact de performance :

- prefix_length : Le nombre de caractères initiaux qui ne seront pas modifiés.
- max_expansions : Limiter les options que la recherche floue génère. La recherche fuzzy arrête de rassembler les termes proches quand elle atteint cette limite



Fuzzy match

La paramètre *fuzziness* modifie la requête match en requête fuzzy

```
GET /my_index/my_type/_search
{
"query": {
   "multi_match": {
     "fields": [ "text", "title" ],
     "query": "SURPRIZE ME!",
     "fuzziness": "AUTO"
} } }
```



Recherches avancées

Recherche avec préfixe Recherche phrase Analyse langage naturel **Surbrillance** Agrégations Géo-localisation



Introduction

La surbrillance consiste à mettre en valeur le terme ayant matché dans le contenu original qui a été indexé.

Cela est possible grâce aux métadonnées stockées lors de l'indexation

Le champ original doit être stocké par ELS



Exemple

```
GET /_search
  "query" : {
    "bool" : {
      "must" : { "match" :
{ "attachment.content" : "Administration"} },
      "should" : { "match" : { "attachment.content" :
"Oracle" } }
  },
  "highlight" : {
        "fields" : {
            "attachment.content" : {}
```



Réponse

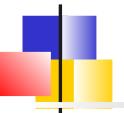
```
"highlight" : {
          "attachment.content" : [
            " formation <em>Administration</em> <em>Oracle</em>
Forms/Report permet de voir tous les aspects nécessaires à",
            " aux autres services Web de l'offre
<em>Oracle Fusion Middleware. Cependant, l'administration
de ces",
            " Surveillance. Elle peut-être un complément de la
formation « <em>Administration</em> d'un serveveur Weblogic",
            "-forme <em>Oracle</em> Forms ou des personnes
désirant migrer leur application client serveur Forms vers",
            " <em>Oracle</em> Forms 11g/12c\nPré-requis : \
nExpérience de l'administration système\nLa formation
« Administation"
```



Types de Highlighter

ELS utilise les « highlighters » de Lucene :

- Plain : Valeur par défaut qui donne les meilleurs résultats mais peut quelquefois causer des soucis de performance
- Posting: Utilisé si la propriété index_options contient offsets dans le mapping. Plus rapide, travaille plutôt sur la phrase.
- Fast-vector: Utilisé si la propriété term_vector est égale à with_positions_offset dans le mapping.
 Plus rapide, surtout pour les champs volumineux (>1MB), peut être affiné par la configuration, ...



Forcer un highlighter

```
GET /_search
  "query" : {
    "bool" : {
      "must" : { "match" :
{ "attachment.content" : "Administration"} },
      "should" : { "match" : { "attachment.content" :
"Oracle" } }
  },
  "highlight" : {
        "fields" : {
            "attachment.content" : { "type" : "plain"}
```



Spécifier les balises

```
GET / search
  "query" : {
    "bool" : {
      "must" : { "match" :
{ "attachment.content" : "Administration"} },
      "should" : { "match" : { "attachment.content" : "Oracle" } }
  },
  "highlight" : {
        "pre_tags" : ["<tag1>"],
        "post_tags" : ["</tag1>"],
        "fields" : {
            "attachment.content" : { "type" : "plain"}
```



Fragments mis en valeur

Il est possible de contrôler les fragments mis en valeur pour chaque champ :

- fragment_size : donne la taille max du fragment mis en surbrillance
- number_of fragments : Le nombre maximal de fragments dans ce champ



Recherches avancées

Recherche avec préfixe Recherche phrase Recherche floue Surbrillance Agrégations Géo-localisation



Introduction

Les agrégations sont extrêmement puissantes pour le reporting et les tableaux de bord

Des énormes volumes de données peuvent être visualisées en temps-réel

 Le reporting change au fur et à mesure que les données changent

L'utilisation de la stack Elastic, Logstash et Kibana démontre bien tout ce que l'on peut faire avec les agrégations.

Exemple (Kibana)





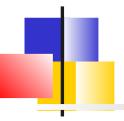
Syntaxe DSL

Une agrégation peut être vue comme une unité de travail qui construit des informations analytiques sur une ensemble de documents.

En fonction de son positionnement dans l'arbre DSL, il s'applique sur l'ensemble des résultats de la recherche ou sur des sousensembles

Dans la syntaxe DSL, un bloc d'agrégation utilise le mot-clé aggs

```
// Le max du champ price dans tous les documents
POST /sales/_search?size=0
{
    "aggs" : {
        "max_price" : { "max" : { "field" : "price" } }
}
```



Types d'agrégations

Plusieurs concepts sont relatifs aux agrégations :

- Groupe ou Buckets: Ensemble de document qui ont un champ à la même valeur ou partagent un même critère.
 Les groupes peuvent être imbriqués. ELS propose des syntaxes pour définir les groupes et compter le nombre de documents dans chaque catégorie
- Métriques : Calculs de métriques sur un groupe de documents (min, max, avg, ..)
- Matrice: (expérimentale) Opérations de classification selon différents champs, produisant une matrice des différentes possibilités. Le scripting n'est pas supporté pour ce type d'agrégation
- Pipeline : Une agrégation s'effectuant sur le résultat d'une agrégation



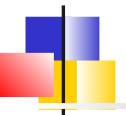
Exemple Bucket

```
GET /cars/transactions/_search
{
"aggs" : {
"colors" : {
    "terms" : { "field" : "color.keyword" }
} } }
```



Réponse

```
"hits": { "hits": [] },
"aggregations": {
"colors": {
  "doc_count_error_upper_bound": 0, // incertitude
  "sum_other_doc_count": 0,
  "buckets": [
    { "key": "red", "doc_count": 4 },
    { "key": "blue", "doc_count": 2 },
    { "key": "green", "doc_count": 2 }
} } }
```

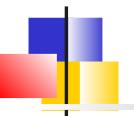


Exemple métrique



Réponse

```
"hits": {
    "total": 8,
    "max_score": 0,
    "hits": []
  "aggregations": {
    "avg_price": {
      "value": 26500
```



Juxtaposition Bucket/Métriques

```
GET /cars/transactions/ search
  "size": 0,
  "aggs" : {
        "colors" : {
            "terms" : { "field" : "color.keyword" }
        "avg price" : {
            "avg" : {"field" : "price"}
```



Réponse

```
"hits": { "hits": [] },
"aggregations": {
   "avg price": {
     "value": 26500
   },
    "colors": {
      "doc_count_error_upper_bound": 0,
      "sum other doc count": 0,
      "buckets": [
        { "key": "red", "doc_count": 4 },
        { "key": "blue", "doc_count": 2 },
        { "key": "green", "doc count": 2 }
 }}
```



Imbrication

```
GET /cars/transactions/ search {
"aggs": {
  "colors": {
    "terms": { "field": "color" },
    "aggs": {
      "avg price": {
        "avg": { "field": "price"}
      }, "make": {
        "terms": { "field": "make" }
} } } }
```



Réponse

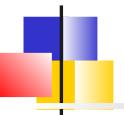
```
"aggregations": {
 "colors": {
   "buckets": [
      { "key": "red",
         "doc_count": 4,
        avg_price": {
            "value": 32500
         },
         "make": { "buckets": [
                            { "key": "honda", "doc_count": 3 },
                            { "key": "bmw", "doc_count": 1 }
         }
    },
. . .
```



Agrégation et recherche

En général, une agrégation est combinée avec une recherche. Les buckets sont alors déduits des seuls documents qui matchent.

```
GET /cars/transactions/_search
{
   "query" : {
       "match" : { "make" : "ford" }
}, "aggs" : {
       "colors" : {
       "terms" : { "field" : "color" }
} } }
```



Spécification du tri

```
GET /cars/transactions/ search
"aggs" : {
  "colors" : {
    "terms" : { "field" : "color",
               "order": { "avg_price" : "asc" }
     }, "aggs": {
        "avg price": {
          "avg": {"field": "price"}
} } } }
```



Types de bucket

Différents types de regroupement sont proposés par ELS

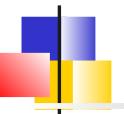
- Par terme, par filtre : Nécessite une tokenization du champ
- Par intervalle de valeurs
- Par intervalle de dates, par histogramme
- Par intervalle d'IP
- Par absence d'un champ
- Par le document parent
- Significant terms
- Par géo-localisation

• ...



Intervalle de valeur

```
GET /cars/transactions/_search
"aggs":{
  "price":{
    "histogram":{
      "field": "price",
      "interval": 20000
    },
   "aggs":{
     "revenue": {
      "sum": { "field" : "price" }
```



Histogramme de date

```
GET /cars/transactions/ search
"aggs": {
  "sales": {
    "date_histogram": {
      "field": "sold",
      "interval": "month",
      "format": "yyyy-MM-dd"
} } }
```

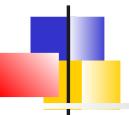


significant_terms

L'agrégation *significant_terms* est plus subtile mais peut donner des résultats intéressants (proche du machine-learning).

Cela consiste à analyser les données retournées et trouver les termes qui apparaissent à une fréquence anormalement supérieure Anormalement signifie : par rapport à la fréquence pour l'ensemble des documents => Ces anomalies statistiques révèlent en général des choses intéressantes

Fonctionnement



significant_terms part d'un résultats d'une recherche et effectue une autre recherche agrégé

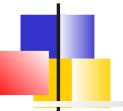
Il part ensuite de l'ensemble des documents et effectue la même recherche agrégé

Il compare ensuite les résultats de la première recherche qui sont anormalement pertinent par rapport à la recherche globale

Avec ce type de fonctionnement, on peut :

- Les personnes qui ont aimé ... ont également aimé ...
- Les clients qui ont eu des transactions CB douteuses sont tous allés chez tel commerçant
- Tous les jeudi soirs, la page untelle est beaucoup plus consultée

– ...



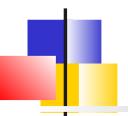
Exemple

```
{
    "query" : {
        "terms" : {"force" : [ "British Transport Police" ]}
},
    "aggregations" : {
        "significantCrimeTypes" : {
            "significant_terms" : { "field" : "crime_type" }
        }
}
```



Réponse

=> Le taux de vols de vélos est anormalement élevé pour « British Transport Police »



Types de métriques

ELS propose de nombreux métriques :

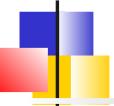
- avg, min, max, sum
- value_count, cardinality :Comptage de valeur distinctes
- top hit : Les meilleurs documents
- extended_stats : Fournit plein de métriques (count, sum, variance, ...)
- percentiles : percentiles



Pipeline

Les agrégations pipelines travaillent sur le résultat d'une agrégation plutôt que sur les documents résultats.

Via leur paramètre **bucket_path**, ils indiquent une agrégation parente ou du même niveau



Exemple

```
POST /_search
{
    "aggs": {
        "my_date_histo":{
            "date_histogram":{
                "field":"timestamp",
                "calendar_interval":"day"
            },
            "aggs":{
                "the_sum":{
                    "sum":{ "field": "lemmings" }
                },
                "the_movavg":{
                    "moving_avg":{ "buckets_path": "the_sum" }
```



Recherches avancées

Recherche avec préfixe Recherche phrase Recherche floue Surbrillance Agrégations **Géo-localisation**



Introduction

ELS permet de combiner la géo-localisation avec les recherches full-text, structurées et les agrégations

ELS a 2 modèles pour représenter des données de géolocalisation

- Le type geo_point qui représente un couple latitude-longitude. Cela permet principalement le calcul de distance
- Le type geo_shape qui définit une zone via le format GeoJSON. Cela permet de savoir si 2 zones ont une intersection



Geo-point

Les Geo-points ne peuvent pas être détectés automatiquement par le dynamic mapping. Ils doivent être explicitement spécifiés dans le mapping:



Filtres

4 filtres peuvent être utilisés pour inclure ou exclure des documents vis à vis de leur *geo-point* :

- geo_bounding_box : Les geo-points inclus dans le rectangle fourni
- geo_distance : Distance d'un point central inférieur à une limite. Le tri et le score peuvent être relatif à la distance
- geo distance range: Distance dans un intervalle
- geo_polygon : Les geo-points incluent dans un polygone



Exemple



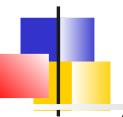
Agrégation

3 types d'agrégation sur les geo-points sont possibles

- geo_distance (bucket): Groupe les documents dans des ronds concentriques autour d'un point central
- geohash_grid (bucket): Groupe les documents par cellules (geohash_cell, les carrés de google maps) pour affichage sur une map
- geo_bounds (metrics): retourne les coordonnées d'une zone rectangle qui engloberait tous les geopoints. Utile pour choisir le bon niveau de zoom

Exemple

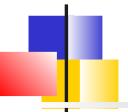
```
GET /attractions/restaurant/_search
"query": { "bool": { "must": {
  "match": { "name": "pizza" }
},
  "filter": {  "geo bounding box": {
       "location": { "top_left": { "lat": 40,8, "lon": -74.1 },
                      "bottom_right": {"lat": 40.4, "lon": -73.7 }
} } } },
  "aggs": {
    "per_ring": {
      "geo distance": {
        "field": "location",
        "unit": "km",
        "origin": {
          "lat": 40.712,
          "lon": -73.988
         },
          "ranges": [
             { "from": 0, "to": 1 },
             { "from": 1, "to": 2 }
} } }
```



Geo-shape

Comme les champs de type *geo_point* , les *geo-shape* doivent être mappés explicitement :

```
PUT /attractions
{
"mappings": { "landmark": {
"properties": {
  "name": { "type": "string" },
   "location": { "type": "geo shape" }
} } } }
PUT /attractions/landmark/dam square
"name" : "Dam Square, Amsterdam",
"location" : {
 "type" : "polygon",
  "coordinates": [[ [ 4.89218, 52.37356 ], [ 4.89205, 52.37276 ], [ 4.89301, 52.37274 ],
[ 4.89392, 52.37250 ], [ 4.89218, 52.37356 ] ]
} }
```



Exemple

```
GET /attractions/landmark/ search
"query": {
  "geo shape": {
   "location": {
    "shape": {
     "type": "circle",
     "radius": "1km"
     "coordinates": [ 4.89994, 52.37815]
```



Exploitation

Index et performance



node-stats API

```
GET nodes/stats
"cluster name": "elasticsearch zach",
"nodes": {
"UNr6ZMf5Qk-YCPA L18B0Q": {
"timestamp": 1408474151742,
"name": "Zach",
"transport address":
"inet[zacharys-air/192.168.1.131:9300]",
"host": "zacharys-air",
"ip": [
"inet[zacharys-air/192.168.1.131:9300]",
"NONE"
```



Sections indices

La section *indices* liste des statistiques agrégés pour tous les les index d'un nœud.

Il contient les sous-sections suivantes :

- docs : combien de documents résident sur le nœud, le nombre de documents supprimés qui n'ont pas encore été purgés
- **store** indique l'espace de stockage utilisé par le nœud
- indexing le nombre de documents indexés
- get : Statistiques des requêtes get-by-ID
- search : le nombre de recherches actives, nombre total de requêtes le temps d'exécution cumulé des requêtes
- merges fusion de segments de Lucene
- filter_cache : la mémoire occupée par le cache des filtres
- id_cache répartition de l'usage mémoire
- field_data mémoire utilisée pour les données temporaires de calcul (utilisé lors d'agrégation, le tri, ...)
- **segments** le nombre de segments Lucene. (chiffre normal 50–150)



Index stats API

L'index stats API permet de visualiser des statistiques vis à vis d'un index

GET my_index/_stats

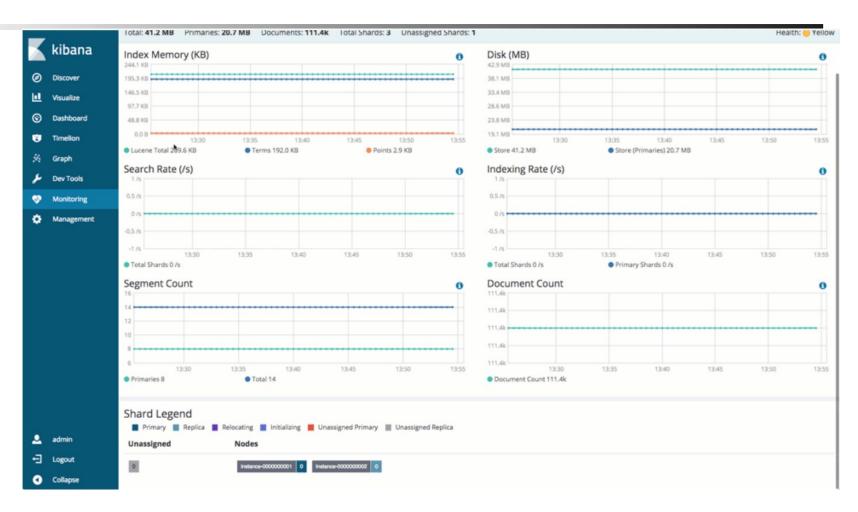
Le résultat est similaire à la sortie de node-stats : Compte de recherche, de get, segments, ...



Exemple XPack1

K	kibana	Clusters / 9ba221b400231fc9c8c6bfaa57234e9 Overview Nodes Indices Jobs	b / Elasticsearch					II 10 seconds 〈 ② Last 30 minutes 〉
0	Discover	Nodes: 3 Indices: 38 Memory: 3GB / 5GB	Total Shards: 75	Unassigned Shards: 2	Documents: 2,154,513	Data: 2GB		Health: O Yellow
u	Visualize							
©	Dashboard	Name I±	Status	Document Count	Data	Index Rate	Search Rate	Unassigned Shards
	Timelion Graph	alerts	Green	2	11.2 KB	0 /s	0 /s	0
	Dev Tools	metricbeat-6.0.0-rc1-2017.10.03	Green	157.1k	66.9 MB	0 /s	0 /s	0
	Monitoring Management	metricbeat-6,0.0-rc1-2017.10.04	Green	21.3k	7.0 MB	0 /s	0 /s	0
		metricbeat-6.0.0-rc1-2017.10.09	Green	901	542.3 KB	0 /s	0 /s	0
		movie_lens_users	Green	138.5k	897.4 MB	0 /s	0 /s	0
		ncedc-earthquakes	Green	38.3k	27.3 MB	0 /s	0 /s	0
		reviews	Green	578.8k	39.1 MB	0 /s	0 /s	0
		shakespeare	Yellow	111.4k	41.2 MB	0 /s	0 /s	1
		slateco	Yellow	5	8.2 KB	0 /s	0 /s	1
_	admin Logout	winlogbeat-6.0.0-rc1-2017.09.01	Green	949	1.2 MB	0 /s	0 /s	0
0	Collapse	winlogbeat-6.0.0-rc1-2017.09.03	Green	94	251 1 KB	0 /s	0 /s	0

Monitoring Shards





Segments Lucene

Chaque shard d'Elasticsearch est un index Lucene.

Un index Lucene est divisé en de petits fichiers : les **segments**

Elasticsearch Index													
	search ard	Elasticsearch shard		Elasticsearch shard		Elasticsearch shard							
Lucene index		Lucene index		Lucene index		Lucene index							
Segment	Segment	Segment	Segment	Segment	Segment	Segment	Segment						



Fusion de segments

Lucene crée des segments lors de l'indexation. Les segments sont immuables

Lors d'une recherche, les segments sont traités de façon séquentielle => Plus il y a de segments, plus les performances de recherche diminuent

Pour optimiser la recherche, Lucene propose l'opération *merge* qui fusionne de petits segments en de plus gros.

- C'est une opération assez lourde qui peut impacter les opérations d'indexation et de recherche. Elle est effectué périodiquement par un pool de threads dédié
- On peut forcer une opération de merge :
 curl -XPOST 'localhost:9200/logstash-2017.07*/_forcemerge?max_num_segments=1'
- Pour que le merge réussisse, il faut que l'espace disque soit 2 fois la taille du shard

Gestion du lifecycle des index

Il est possible d'automatiser des actions de gestion du cycle de vie des index comme :

- Rollover : Redirigez un alias pour commencer à écrire dans un nouvel index lorsque l'index existant atteint un certain âge, nombre de documents ou taille.
- Shrink : Réduire le nombre de shards primaires dans un index.
- Force merge : Réduire le nombre de segments dans chaque shards d'un index et libérer l'espace utilisé par les documents supprimés.
- Freeze : Rendre un index read-only et minimiser son empreinte mémoire
- **Delete** : Supprimer un index



Mécanisme

En pratique, il faut associer une **stratégie de cycle de vie avec un gabarit d'index**, afin qu'il soit appliqué aux index nouvellement créés.

La stratégie de cycle de vie définit les conditions pour faire un index dans ses différentes de son cycle de vie :

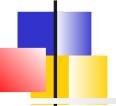
- Hot : L'index est mis à jour et interrogé
- Warm : L'index n'est plus mis à jour mais encore interrogé.
- Cold: L'index n'est plus mis à jour et est rarement interrogé. Les informations sont toujours consultables, mais les requêtes sont plus lentes
- Delete: L'index n'est plus utilisé et peut être supprimé.



Stratégies

Une stratégie de cycle de vie consiste à spécifier :

- Taille ou âge maximum pour effectuer le rollover.
- Le moment où l'index n'est plus mis à jour et ou le nombre de shards primaires peut être réduit.
- Le moment pour forcer la fusion
- Le moment ou on peut déplacer l'index vers un matériel moins performant.
- Le moment où la disponibilité n'est pas aussi critique et le nombre de répliques peut être réduit.
- Le moment où l'index peut être supprimé en toute sécurité.



Création

```
PUT _ilm/policy/datastream_policy
  "policy": {
    "phases": {
      "hot": {
        "actions": {
          "rollover": {
            "max_size": "50GB",
            "max_age": "30d"
      },
      "delete": {
        "min_age": "90d",
        "actions": {
          "delete": {}
```



Création de gabarit puis du premier index

```
PUT _template/datastream_template
  "index_patterns": ["datastream-*"],
  "settings": {
    "number of shards": 1,
    "number_of_replicas": 1,
    "index.lifecycle.name": "datastream_policy",
    "index.lifecycle.rollover_alias": "datastream"
PUT datastream-000001
  "aliases": {
    "datastream": {
      "is_write_index": true
GET datastream-*/_ilm/explain
```



Exploitation

Changement de configuration

La plupart des configurations ELS sont dynamiques, elles peuvent être modifiées par l'API.

L'API cluster-update opère selon 2 modes :

- transient : Les changements sont annulés au redémarrage
- persistent : Les changements sont permanents. Au redémarrage, ils écrasent les valeurs des fichiers de configuration



Exemple

```
PUT /_cluster/settings
{
   "persistent" : {
   "discovery.zen.minimum_master_nodes" : 2
},
   "transient" : {
   "indices.store.throttle.max_bytes_per_sec" : "50mb"
647}
}
```



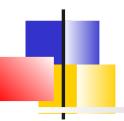
Fichiers de trace

ELS écrit de nombreuses traces dans ES_HOME/logs . Le niveau de trace par défaut est INFO

On peut le changer par l'API

```
PUT /_cluster/settings
{
"transient" : { "logger.discovery" : "DEBUG" }
}
OU
PUT /_cluster/settings {
"transient":{"logger._root":"DEBUG"}
}
```

Ne pas oublier la config. Initiale de log4j42.properties



Quelques packages ELS

```
org.elasticsearch.env: Relatif à l'emplacement des
données des nœuds (data)
org.elasticsearch.indices.recovery et
org.elasticsearch.index.gateway : Recouvrement de
shards
org.elasticsearch.cluster.action.shard : Statut des
shards
org.elasticsearch.snapshots : Pour les
snapshots&restore
org.elasticsearch.http : Connexion réseaux
org.elasticsearch.marvel.agent.exporter : Log du
monitoring
```



Slowlog

L'objectif du **slowlog** est de logger les requêtes et les demandes d'indexation qui dépassent un certain seuil de temps

Par défaut ce fichier journal n'est pas activé. Il peut être activé en précisant l'action (query, fetch, ou index), le niveau de trace (WARN, DEBUG, ..) et le seuil de temps

C'est une configuration au niveau index

```
PUT /my_index/_settings
{ "index.search.slowlog.threshold.query.warn" : "10s",
   "index.search.slowlog.threshold.fetch.debug": "500ms",
   "index.indexing.slowlog.threshold.index.info": "5s" }

PUT /_cluster/settings
{ "transient" : {
    "logger.index.search.slowlog" : "DEBUG",
    "logger.index.indexing.slowlog" : "WARN"
} }
```

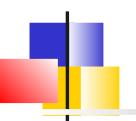


Annexes

Routing
Distribution de la recherche
Types complexes
Mapping relation parent/enfant
Requête avec jointure
Client Java
Pipeline d'agrégations



Routing



Résolution du shard primaire

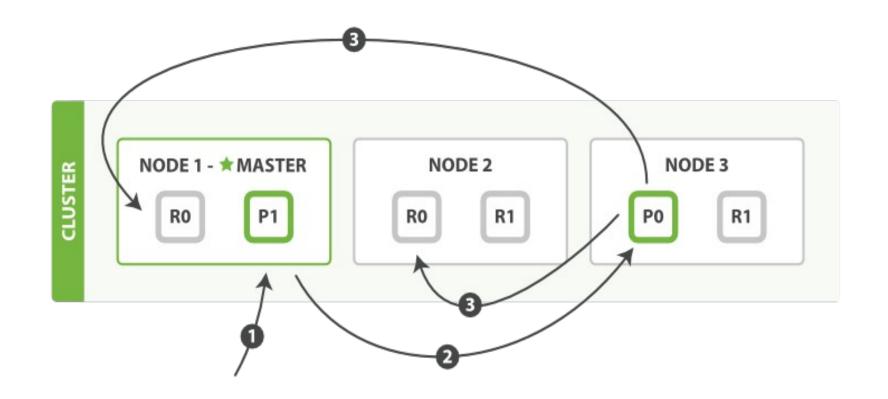
Lors de l'indexation, le document est d'abord stocké sur le shard primaire.

La résolution du n° de shard s'effectue grâce à la formule :

shard = hash(routing) % number_of_primary_shards

La valeur du paramètre *routing* est une chaîne arbitraire qui par défaut correspond à l'*id* du document mais peut être explicitement spécifiée

Séquence d'une mise à jour sur une architecture cluster

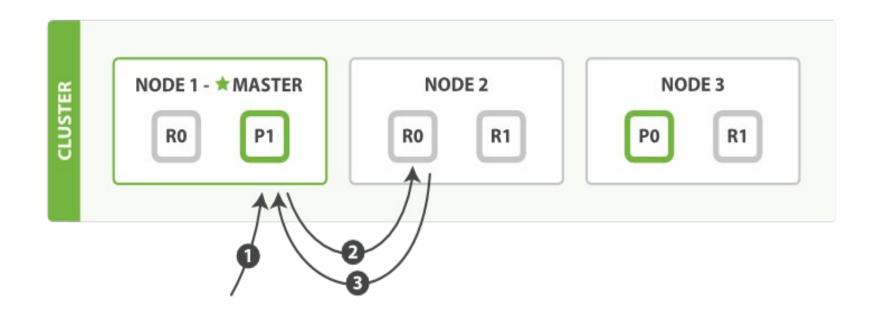




Séquence d'une mise à jour sur une architecture cluster (2)

- 1. Le client envoie une requête d'indexation ou suppression vers le nœud 1
- 2. Le nœud utilise l'id du document pour déduire que le document appartient au shard 0. Il transfert la requête vers le nœud 3, ou la copie primaire du shard 0 réside.
- 3. Le nœud 3 exécute la requête sur le shard primaire. Si elle réussit, il transfère la requête en parallèle aux répliques résidant sur le nœud 1 et le nœud 2. Une fois que les ordres de mises à jour des réplicas aboutissent, le nœud 3 répond au nœud 1 qui répond au client

Séquence pour la récupération d'un document



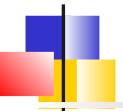


Séquence pour la récupération d'un document

- 1. Le client envoie une requête au nœud 1.
- 2. Le nœud utilise l'id du document pour déterminer que le document appartient au shard 0. Des copies de shard 0 existent sur les 3 nœuds Pour cette fois-ci, il transfert la requête au nœud 2.
- 3. Le nœud 2 retourne le document au nœud 1 qui le retourne au client.

Pour les prochaines demandes de lecture, le nœud choisira un shard différent pour répartir la charge (algorithme Round-robin)

TP 2: Document API 253



Distribution de la recherche



Introduction

La recherche nécessite un modèle d'exécution complexe les documents correspondant à la recherche sont dispersés sur les shards

Une recherche doit consulter une copie de chaque shard de l'index ou des index sollicités

Une fois trouvés ; les résultats des différents shards doivent être combinés en une liste unique afin que l'API puisse retourner une page de résultats

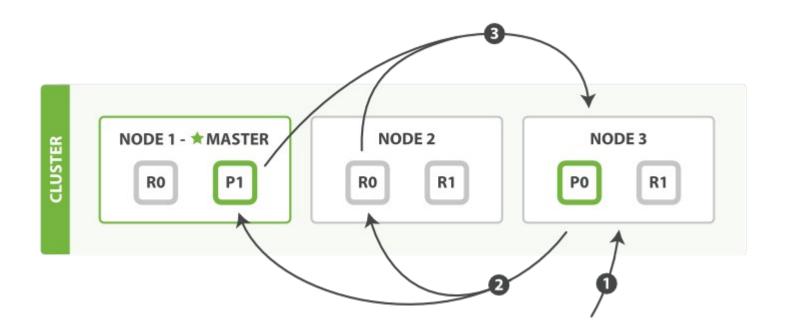
La recherche est donc exécutée en 2 phases :

- query
- fetch.



Phase de requête

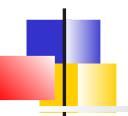
Durant la 1ère phase, la requête est diffusée à une copie (primaire ou réplique) de tous les shards. Chaque shard exécute la recherche et construit une file à priorité des documents qui matchent





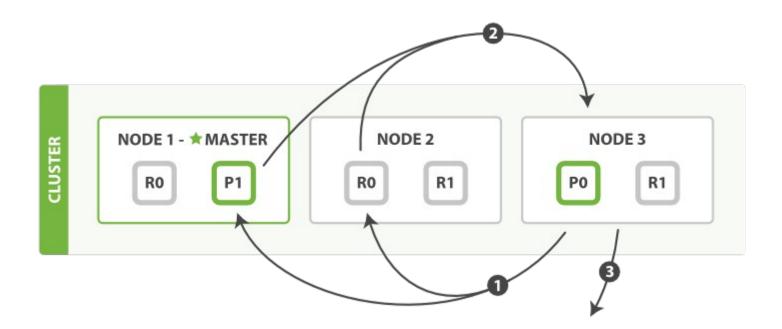
Phase de requête

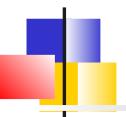
- 1. Le client envoie une requête de recherche au nœud 3 qui crée une file à priorité vide de taille from + size.
- 2. Le nœud 3 transfère la requête à une copie de chaque shard de l'index. Chaque shard exécute la requête localement et ajoute le résultat dans une file à priorité locale de taille *from* + *size*.
- 3. Chaque shard retourne les IDs et les valeurs de tri de tous les documents de la file au nœud 3 qui fusionne ces valeurs dasn sa file de priorité



Phase fetch

La phase de fetch consiste à récupérer les documents présents dans la file à priorité.

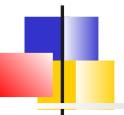




Phase fetch

- 1. Le nœud coordinateur identifie quels documents doivent être récupérés et produit une requête multiple GET aux shards.
- 2. Chaque shard charge les documents, les enrichi si nécessaire (surbrillance par exemple) et les retourne au nœud coordinateur
- 3. Lorsque tous les documents ont été récupérés, le coordinateur retourne les résultats au client.

Types complexes



Types complexes

En plus des types simples, ELS supporte

 Les tableaux : Il n'y a pas de mapping spécial pour les tableaux. Chaque champ peut contenir 0, 1 ou n valeurs

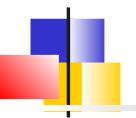
```
{ "tag": [ "search", "nosql" ]}
```

- Les valeurs d'un tableau doivent être de même type
- Un champ à null est traité comme un tableau vide
- Les objets : Il s'agit d'une structure de données embarquées dans un champ
- Les nested : Il s'agit d'un tableau de structures de données embarquées dans un champ. Chaque élément du tableau est stocké séparément

Mapping des objets embarqués

ELS détecte dynamiquement les champs objets et les mappe comme objet. Chaque champ embarqué est listé sous *properties*

```
{ "gb": {
  "tweet": {
    "properties": {
      "tweet" { "type": "string" }:
      "user": {
        "type": "object",
        "properties": {
           "id": { "type": "string" },
           "age": { "type": "long"},
           "name": {
             "type": "object",
             "properties": {
               "first": { "type": "string" },
               "last": { "type": "string" }
}} } } }
```



Indexation des objets embarqués

Un document Lucene consiste d'une liste à plat de paires clé/valeurs. Les objets embarqués sont alors convertis comme suit : "tweet":[elasticsearch, flexible, very], "user.id": [@johnsmith], "user.age": [26], "user.name.first": [john], "user.name.last": [smith]

Attention!

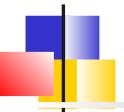
```
"followers": [
{ "age": 35, "name": "Mary White"},
{ "age": 26, "name": "Alex Jones"},
{ "age": 19, "name": "Lisa Smith"}]
Après indexation, cela donne :
{
"followers.age": [19, 26, 35],
"followers.name": [alex, jones, lisa, smith, mary, white]
}
=> Lien entre age et nom perdu!
q=age:19 AND name:Mary retourne des résultats
=> Solution les Nested objects
```



Type nested

Pour garder l'indépendance de chaque objet, il faut déclarer un type **nested**

Cela a pour effet de créer des « sous-documents » indépendants et chaque sous-document peut être recherché indépendamment (Voir nested query)



Champs méta et relation parent/enfant



Méta-données

Chaque document a des méta-données associés :

Identification:

- -_index, _type, _id
- _uid : Champ composite constitué de _type et _id

Document original:

- **source** : Le JSON original.
- **size** : La taille en octets

Indexation

- all: Contient toutes les valeurs des autres champs
- _field_names : Tous les champs qui contiennent une valeur non-null.

Routing

- parent : Utilisé pour créer une relation parent-enfant entre 2 types de document
- _routing : Une valeur personnalisée pour le routing

Autres

– _meta : Méta-données applicatives



Relation parent/enfant

6.x

```
PUT my_index
  "mappings": {
    "_doc": {
      "properties": {
        "my_join_field": { // Nom du champ
          "type": "join",
          "relations": {
            "question": "answer" // Relation One To Many
```



6.x

```
# Indexation document parent
PUT my_index/_doc/1?refresh
  "text": "This is a question",
  "my_join_field": {
   "name": "question"
# Indexation document enfant
PUT my_index/_doc/3?routing=1&refresh
  "text": "This is an answer",
  "my join field": {
    "name": "answer",
    "parent": "1"
```



Jointures



Introduction

ELS permet 2 types de requêtes s'apparentant à des jointures SQL

- Requête sur objets imbriqués : Ce type de requête permet de récupérer des documents en fonction de critères sur ses objets imbriqués
- Requête parent/enfant : Les requêtes has_child et has_parent permettent de retrouver un document en fonction de critère sur son parent ou ses enfants



Requête imbriquée

Les requêtes imbriquées utilisent les paramètres suivants :

- nested : Encapsule les informations concernant la requête imbriquée
- path : référence le chemin vers l'objet imbriqué
- query : inclut la requête exécutée sur les objets imbriqués. Les champs référencés dans la requête doivent utiliser le chemin complet
- score_mode : spécifie comment le score des enfants influence le score du document parent retourné. Par défaut <u>avg</u>, mais peut être <u>sum</u>, <u>min</u>, max et <u>none</u>.



Exemple

```
GET /_search
    "query": {
        "nested" : {
            "path" : "obj1",
            "score_mode" : "avg",
            "query" : {
                "bool" : {
                    "must" : [
                    { "match" : {"objl.name" : "blue"} },
                    { "range" : {"obj1.count" : {"gt" : 5}} }
```



Requête has_child

Le filtre *has_child* spécifie 2 valeurs :

- type : Le type de documents sur lesquels portent la recherche
- query : La requête ELS

Il retourne des documents parents dont les enfants vérifient la requête

Il peut également préciser d'autres paramètres :

- score_mode : Comment le score des enfants sont agrégés dans le parent
- min_children, max_children : Limitation sur le nombre d'enfants

Exemple

```
GET /_search
    "query": {
        "has_child" : {
            "type" : "blog_tag",
            "score_mode" : "min",
            "min_children": 2,
            "max_children": 10,
            "query" : {
                "term" : {
                     "tag" : "something"
```

-

Exemple

```
GET /_search
    "query": {
        "has_child" : {
            "type" : "blog_tag",
            "score_mode" : "min",
            "min_children": 2,
            "max_children": 10,
            "query" : {
                "term" : {
                     "tag" : "something"
```



Requête has_parent

Le filtre *has_parent* spécifie 2 valeurs :

- parent_type : Le type des documents parents
- query : La requête ELS

Il retourne des documents enfants dont les parents vérifient la requête

Il peut également préciser d'autres paramètres :

 score : Le score du parent est il agrégé dans l'enfant



Exemple

```
GET /_search
    "query": {
        "has_parent" : {
            "parent_type" : "blog",
            "score" : true,
            "query" : {
                "term" : {
                     "tag" : "something"
```



Requête parent_id

La requête *parent_id* renvoie tout simplement les enfants d'un parent particulier.

Elle est plus efficace que has_parent

Exemple:



inner hits

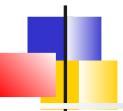
Lors de requêtes parent/child ou nested, les causes du match dans les objets embarqués (nested, parent ou child) ne sont pas affichées par défaut.

Le bloc *inner_hits* permet de donner plus d'explications sur les résultats retournés

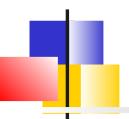


Structure

```
Requéte:
"<query>" : {
    "inner_hits" : {
        <inner_hits_options>
Réponse :
"hits": [
        " index": ...,
        __type": ...,
        "id": ...,
        "inner_hits": {
           "<inner_hits_name>": {
              "hits": {
                 "total": ...,
                 "hits": [
                       "_type": ...,
                       "_id": ...,
                    },
                 ] } } },
                  ... }, ... ]
```



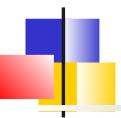
Client Java



2 approches

2 API Java pour les clients REST sont fournies par elastic :

- API de bas niveau : Il faut sérialiser/désérialiser soi-même
- API de haut niveau : Méthodes spécifiques effectuant les sérialisation/désérialisation



Apports API de bas-niveau

- Dépéndances minimales
- Répartition de charge entre les nœuds du cluster
- Failover si défaillance de nœud
- Les nœuds ne répondant pas correctement sont pénalisés
- Connexions TCP persistantes
- Journalisation des requêtes et des réponses
- Découverte automatique des noeuds



Dépendances

Maven:

Gradle:

```
dependencies {
     compile 'org.elasticsearch.client:elasticsearch-rest-
client:7.5.2'
}
```



Initialisation

Initialisation en fournissant une ou plusieurs adresses de nœud :

```
RestClient restClient = RestClient.builder(
    new HttpHost("localhost", 9200, "http"),
    new HttpHost("localhost", 9201, "http")).build();
```

Thread safe => généralement un singleton

restClient.close() quand il n'est plus requis



Options avancées

Le builder propose d'autres options à l'instanciation :

- Positionner des entêtes
- Des listener pour écouter les défaillances de nœud
- Des sélecteurs de nœuds permettant de filtrer les nœuds sollicités
- La définition de callback permettant de modifier la configuration des requêtes et du client (timeout, ssl, ...)



Requêtes

performRequest : Appel synchrone

```
Request request = new Request(
    "GET",
    "/");
Response response = restClient.performRequest(request);
```

• **performRequestAsync**: Appel asynchrone avec un argument de type ResponseListener et retournant un objet Cancellable

```
Request request = new Request("GET", "/");
Cancellable cancellable = restClient.performRequestAsync(request,
    new ResponseListener() {
      public void onSuccess(Response response) { }
      public void onFailure(Exception exception) { }
});
```



Données de la requête

Ajout d'un paramètre :

```
request.addParameter("pretty", "true");
Positionnement du corps de la requête
```

Possibilité de mutualiser les options dans une instance de type *RequestOption* (entêtes, sélecteur de nœud, buffer de réponses)



Réponses

L'objet *Response* retourné par l'appel synchrone ou passé en argument à la méthode onsuccess

```
Response response = restClient.performRequest(new Request("GET", "/"));
RequestLine requestLine = response.getRequestLine();
HttpHost host = response.getHost();
int statusCode = response.getStatusLine().getStatusCode();
Header[] headers = response.getHeaders();
String responseBody = EntityUtils.toString(response.getEntity());
```

2 types d'exceptions :

- *IOException* : Communication
- ResponseException : Code!= 2xx



Sniffer

Un sniffer permet de rafraîchir périodiquement la liste des nœuds

```
RestClient restClient = RestClient.builder(
   new HttpHost("localhost", 9200, "http"))
   .build();
Sniffer sniffer = Sniffer.builder(restClient).build();
```

Le rafraîchissement peut également être provoqué lors d'une erreur



High-Level

Java 8

La version du client doit correspondre à celle des nœuds ELS (au moins la version majeure)

Maven



Initialisation

```
RestHighLevelClient client = new
RestHighLevelClient(
   RestClient.builder(
    new HttpHost("localhost", 9200, "http"),
    new HttpHost("localhost", 9201, "http")));
// Quand plus nécessaire
client.close();
Possibilité également des positionner les options via
RequestOption
```



Objets Request

L'API propose de nombreux objets Request en fonction de l'opération que l'on veut effectuer, des objets Response spécifique sont alors retournés :

IndexRequest/IndexResponse pour indexer un document

GetRequest/GetResponse pour récupérer un document

CreateIndexRequest/CreateIndexResponse pour créer un index

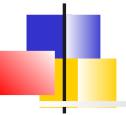
PutMappingRequest/AcknowledgedResponse pour spécifier un mapping

SearchRequest/SearchResponse: recherche, indexation, suggestion

MultiSearchRequest/MultiSearchResponse pour effectuer plusieurs requêtes en 1 seule requête HTTP

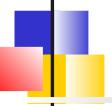
ClusterHealthRequest/ClusterHealthResponse pour la santé du cluster PutPipelineRequest/AcknowledgedResponse pour positionner une pipeline

. . .



Exemples: Indexation

```
IndexRequest request = new IndexRequest("posts");
request.id("1");
String jsonString = "{" +
        "\"user\":\"kimchy\"," +
        "\"postDate\":\"2013-01-30\"," +
        "\"message\":\"trying out Elasticsearch\"" +
        "}";
request.source(jsonString, XContentType.JSON);
Map<String, Object> jsonMap = new HashMap<>();
jsonMap.put("user", "kimchy");
jsonMap.put("postDate", new Date());
jsonMap.put("message", "trying out Elasticsearch");
IndexRequest indexRequest = new IndexRequest("posts")
    .id("1").source(jsonMap);
```



IndexResponse

```
String index = indexResponse.getIndex();
String id = indexResponse.getId();
if (indexResponse.getResult() == DocWriteResponse.Result.CREATED) {
} else if (indexResponse.getResult() == DocWriteResponse.Result.UPDATED) {
}
ReplicationResponse.ShardInfo shardInfo = indexResponse.getShardInfo();
if (shardInfo.getTotal() != shardInfo.getSuccessful()) {
if (shardInfo.getFailed() > 0) {
    for (ReplicationResponse.ShardInfo.Failure failure :
            shardInfo.getFailures()) {
        String reason = failure.reason();
```



SearchSourceBuilder

Lors d'une requête de type *SearchRequest*, un objet *SearchSourceBuilder* est utilisé pour spécifier tous les paramètres de requêtes

Cet objet s'appuie également sur des objets de type QueryBuilder

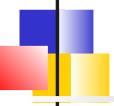
```
SearchRequest searchRequest = new SearchRequest();
SearchSourceBuilder sourceBuilder = new SearchSourceBuilder();
sourceBuilder.query(QueryBuilders.termQuery("user", "kimchy"));
sourceBuilder.from(0);
sourceBuilder.size(5);
sourceBuilder.timeout(new TimeValue(60, TimeUnit.SECONDS));
searchRequest.source(searchSourceBuilder);
```



SearchResponse et SearchHits

L'objet retourné **SearchResponse** donne tous les informations sur la recherche et en particulier les **SearchHits**

```
RestStatus status = searchResponse.status();
TimeValue took = searchResponse.getTook();
Boolean terminatedEarly =
searchResponse.isTerminatedEarly();
boolean timedOut = searchResponse.isTimedOut();
int totalShards = searchResponse.getTotalShards();
int successfulShards =
searchResponse.getSuccessfulShards();
int failedShards = searchResponse.getFailedShards();
SearchHits hits = searchResponse.getHits();
```



SearchHits

```
TotalHits totalHits = hits.getTotalHits();
float maxScore = hits.getMaxScore();
SearchHit[] searchHits = hits.getHits();
for (SearchHit hit : searchHits) {
  String index = hit.getIndex();
  String id = hit.getId();
  float score = hit.getScore();
  String sourceAsString = hit.getSourceAsString();
  Map<String, Object> sourceAsMap = hit.getSourceAsMap();
  String documentTitle = (String) sourceAsMap.get("title");
  List<Object> users = (List<Object>) sourceAsMap.get("user");
  Map<String, Object> innerObject =
     (Map<String, Object>) sourceAsMap.get("innerObject");
}
```

Exemple: Recherche multiple

```
MultiSearchRequest request = new MultiSearchRequest();
SearchRequest firstSearchRequest = new SearchRequest();
SearchSourceBuilder searchSourceBuilder = new SearchSourceBuilder();
searchSourceBuilder.query(QueryBuilders.matchQuery("user", "kimchy"));
firstSearchRequest.source(searchSourceBuilder);
request.add(firstSearchRequest);
SearchRequest secondSearchRequest = new SearchRequest();
searchSourceBuilder = new SearchSourceBuilder();
searchSourceBuilder.query(QueryBuilders.matchQuery("user", "luca"));
secondSearchRequest.source(searchSourceBuilder);
request.add(secondSearchRequest);
```



Agrégations pipeline



Agrégations pipeline

Les agrégations de type pipeline travaillent à partir d'une sortie produite par une autre agrégation.

Il y en a de 2 types :

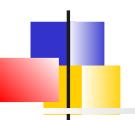
- Parent : Leurs entrées proviennent d'une agrégation parente et permettent de calculer de nouveaux groupements ou métriques sur les groupement parents
- Sibling: Leurs entrées proviennent d'une agrégation juxtaposée et permettent de calculer une nouvelle agrégation du même niveau

Dans les 2 cas, le chemin d'entrée est fourni par le paramètre **bucket_path**



Syntaxe du bucket_path

```
'>' ;
AGG SEPARATOR
METRIC_SEPARATOR = '.';
                     = <le nom de l'aggregation> ;
AGG_NAME
METRIC
                     = <Le nom du metric> :
                        <AGG NAME> [ <AGG SEPARATOR>,
PATH
<AGG_NAME> ]* [ <METRIC_SEPARATOR>, <METRIC> ] ;
Par exemple:
my bucket>my stats.avg
i.e La valeur moyenne dans le métrique my stats contenu dans le bucket my bucket
Les chemins sont relatifs et ne peuvent pas remonter dans l'arborescence
```



Quelques pipelines agrégations

```
avg_bucket, moving avg (sibling): calcule la
moyenne (mouvante) d'un autre métrique
derivative (sibling) : Fonction dérivée
min bucket, max bucket (sibling): Min et max
sum bucket (sibling) : Somme
cumulative sum (parent):
bucket_script (parent) : Exécution d'un script
. . .
```



Exemple

```
POST /_search
    "aggs": {
        "my_date_histo":{
            "date_histogram":{
                "field":"timestamp",
                "interval": "day"
            },
            "aggs":{
                "the_sum":{
                    "sum":{ "field": "lemmings" }
                },
                "the_movavg":{
                    "moving_avg":{ "buckets_path": "the_sum" }
```

7

Exemple 2

```
POST /_search
    "aggs" : {
        "sales_per_month" : {
            "date_histogram" : {
                "field" : "date",
                "interval" : "month"
            },
            "aggs": {
                "sales": {
                    "sum": {
                        "field": "price"
        },
        "max_monthly_sales": {
            "max_bucket": {
                "buckets_path": "sales_per_month>sales"
}
```



Exemple 3

```
# Utilisation du path _count
POST /_search
    "aggs": {
        "my_date_histo": {
            "date_histogram": {
                "field": "timestamp",
                "interval":"day"
            },
            "aggs": {
                "the_movavg": {
                    "moving_avg": { "buckets_path": "_count" }
```